

EducationQ: Deep Dive & Diễn giải

Đánh giá năng lực dạy học của LLM qua Framework Đối thoại Đa tác tử

Paper gốc: Yao Shi, Rongkeng Liang, Yong Xu — ACL 2025 Main Conference
South China University of Technology · Education Innovation Research Institute of Guangdong
arXiv:2504.14928 · github.com/SunriserFuture/EducationQ

Tài liệu diễn giải, phân tích sâu & chuẩn bị vấn đáp — Tiếng Việt

Mục lục

- Câu chuyện mở đầu — Vì sao paper này tồn tại
- Bối cảnh nghiên cứu — Bức tranh toàn cảnh
- Nền tảng lý thuyết giáo dục — Bốn trụ cột
- Kiến trúc EducationQ — Ba tác tử, ba pha
- Dữ liệu đánh giá — 1.498 câu hỏi
- Hệ thống đo lường — Bốn thước đo
- Kết quả thực nghiệm — Phân tích sâu
- Kiểm chứng bởi chuyên gia
- Giới hạn & hướng phát triển
- Tổng kết & Ý nghĩa

1. Câu chuyện mở đầu — Vì sao paper này tồn tại

Hãy bắt đầu bằng một câu hỏi đơn giản: **Nếu một LLM đạt 90% trên MMLU, liệu nó có thể dạy một sinh viên hiểu bài không?**

Câu trả lời trực giác của hầu hết mọi người là "có" — model biết nhiều thì chắc dạy giỏi. Nhưng EducationQ chứng minh điều ngược lại. Llama 3.1 70B Instruct, một model open-source với 70 tỷ tham số, dạy hiệu quả gấp gần 1.8 lần so với Llama 3.1 405B Instruct — model cùng dòng nhưng lớn hơn 5.8 lần. Claude 3.5 Sonnet, một trong những model thương mại mạnh nhất, xếp hạng 9 trên 14 về năng lực dạy học.

Phát hiện này không chỉ đáng ngạc nhiên — nó cho thấy một **khoảng trống nghiêm trọng** trong cách chúng ta đánh giá LLM. Toàn bộ hệ sinh thái benchmark hiện tại, từ MMLU đến Chatbot Arena, đo một thứ — khả năng *trả lời*. Không ai đo khả năng *dạy*.

Đây là điểm xuất phát của EducationQ. Paper không chỉ giới thiệu một benchmark mới — nó đặt ra một câu hỏi nghiên cứu hoàn toàn khác: **"LLM có dạy được không, và nếu có, model nào dạy giỏi nhất?"**

1.1 Sự khác biệt giữa "biết" và "dạy"

Trong đời thực, chúng ta đều hiểu sự khác biệt này. Một giáo sư xuất sắc về vật lý lượng tử có thể giảng

bài rất tệ nếu không biết: (a) đặt câu hỏi gợi mở thay vì đưa đáp án, (b) đánh giá mức hiểu biết hiện tại của sinh viên, (c) điều chỉnh cách giải thích theo từng người, (d) biết khi nào nên giải thích thêm và khi nào nên để sinh viên tự khám phá.

LLM cũng vậy. MMLU đo "model biết bao nhiêu kiến thức?" HumanEval đo "model code giỏi không?" MT-Bench đo "câu trả lời có hay không?" Nhưng **không benchmark nào đo "model có khiến người học hiểu hơn sau khi tương tác không?"** — và đó mới là bản chất của dạy học.

1.2 Ba paradigm đánh giá hiện tại — và vì sao tất cả đều thất bại

Paper phân tích ba cách đánh giá LLM hiện tại và chỉ ra hạn chế cụ thể của từng cách khi áp dụng vào giáo dục:

Paradigm 1: Closed-ended benchmarks

Đại diện: MMLU, MMLU-Pro, GPQA, MATH, HumanEval. Cơ chế: đặt câu hỏi đóng, model chọn đáp án, chấm đúng/sai.

Ưu điểm: hoàn toàn tự động, scale được, reproducible, có thể so sánh trực tiếp. Đây là lý do chúng thống trị — dễ làm, dễ hiểu, dễ so sánh.

Hạn chế cho giáo dục: chúng biến LLM thành "thí sinh" (test-taker), không phải "giáo viên" (teacher). Không có tương tác — một câu hỏi, một câu trả lời, xong. Không đo khả năng chủ động đặt câu hỏi, chọn chiến lược, thích ứng theo phản hồi. Nói ngắn gọn: đo "model biết gì" chứ không đo "model dạy giỏi thế nào."

Paradigm 2: Open-ended / Human preference

Đại diện: MT-Bench, Chatbot Arena, IFEval, FLAN. Cơ chế: model trả lời mở, con người đánh giá chất lượng.

Hạn chế: ưu tiên sai mục tiêu cho giáo dục. MT-Bench/Chatbot Arena đo "general user satisfaction" — người dùng thích câu trả lời nào hơn. Nhưng một câu trả lời eloquent, comprehensive, detailed không nhất thiết là một bài giảng hiệu quả. Ngược lại, một bài giảng hiệu quả có thể trông "ít ấn tượng" vì giáo viên giỏi **không đưa đáp án** — họ đặt câu hỏi để học sinh tự tìm ra. Thêm vào đó, phương pháp này phụ thuộc human judgment nên không scale được, tốn kém, và không reproducible.

Paradigm 3: Multi-turn dialogue

Đại diện: MathChat (Liang et al., 2024). Cơ chế: đánh giá LLM trong tương tác nhiều lượt.

Hạn chế: có tương tác nhưng thiếu cơ chế cụ thể để gợi ra (elicit) hành vi giảng dạy và đo lường hiệu quả dạy học. MathChat phát hiện rằng models gặp khó khăn với sustained reasoning qua nhiều lượt — nhưng không đo teaching effectiveness. Có dialogue nhưng không có vai trò teacher rõ ràng, không có pre-test/post-test, không có evaluator chuyên giáo dục.

Gap Statement (trích từ Abstract): "This finding highlights a critical gap in current evaluations that prioritize knowledge recall over interactive pedagogy." — Tạm dịch: Các đánh giá hiện tại ưu tiên "nhớ kiến thức" hơn "sự phạm tương tác" — và khoảng cách giữa hai điều này rất lớn.

1.3 Năm chức năng giảng dạy mà benchmark hiện tại bỏ lỡ

Paper viện dẫn nghiên cứu giáo dục kinh điển để liệt kê cụ thể những gì bị thiếu: (1) dẫn dắt quá trình học — Palincsar, 1998, (2) tạo điều kiện xây dựng kiến thức — Hmelo-Silver & Barrows, 2006, (3) tổ chức hoạt động giáo dục — Mercer & Littleton, 2007, (4) cung cấp phản hồi cá nhân hóa — Pardo et al., 2019, (5) scaffolding phát triển kỹ năng — Wood, Bruner & Ross, 1976.

Đây không phải danh sách ngẫu nhiên — mỗi mục đều có nền tảng lý thuyết hàng chục năm. Và không benchmark nào hiện tại capture được bất kỳ mục nào trong số này. Đó là lý do paper tồn tại.

2. Bối cảnh nghiên cứu — Bức tranh toàn cảnh

Trước khi đi vào framework, cần hiểu EducationQ đứng ở đâu trong landscape nghiên cứu hiện tại. Paper chia Related Work thành ba mảng:

2.1 LLM Evaluation — Ai đang đo gì?

Task-oriented benchmarks: MMLU (Hendrycks et al., 2021a) đo kiến thức đa lĩnh vực qua câu hỏi trắc nghiệm. MMLU-Pro (Wang et al., 2024b) nâng cấp với 10 options thay vì 4, tăng robustness. GPQA (Rein et al., 2023) tập trung vào câu hỏi cấp chuyên gia — khó đến mức non-experts đạt dưới 33%. MATH (Hendrycks et al., 2021b) đo suy luận toán học. HumanEval (Chen et al., 2021) đo lập trình. Tất cả đều single-turn, closed-ended.

Instruction following: IFEval (Zhou et al., 2023), FLAN (Wei et al., 2022), Self-Instruct (Wang et al., 2023), NaturalInstructions (Wang et al., 2022). Đo khả năng hiểu và thực hiện chỉ dẫn — mở hơn nhưng vẫn không đo dạy học.

Human preference alignment: MT-Bench và Chatbot Arena (Zheng et al., 2023). Ưu tiên trải nghiệm người dùng tổng quát, không phải kết quả giáo dục.

Điểm mấu chốt: **không paradigm nào đặt LLM vào vai trò giáo viên** — tất cả đều đặt LLM vào vai trò "người trả lời" hoặc "người thực hiện."

2.2 LLM-Enhanced Benchmark Development — Công cụ mới

Xu hướng dùng LLM để xây dựng và cải thiện benchmark. MMLU-Pro dùng GPT-4-Turbo để mở rộng distractor options. Benchmark Self-Evolving (Wang et al., 2024a) dùng LLM tự mở rộng benchmark, giảm data contamination. Dr.Academy (Chen et al., 2024) dùng GPT-4 đánh giá chất lượng nội dung sinh ra.

Zheng et al. (2023) chứng minh GPT-4 có thể thay thế human judges trong MTBench với chất lượng tương đương — đây là tiền đề quan trọng cho việc EducationQ dùng GPT-4o làm evaluator agent.

2.3 LLM-Based Student Modeling — Tiền đề cho student agent

Đây là mảng liên quan trực tiếp nhất. Park et al. (2023) cho thấy LLM có thể mô phỏng hành vi và nhận thức con người. Xu & Zhang (2023) nghiên cứu tính khả thi của "generative students" để test tài liệu giáo dục. Markel et al. (2023) — GPTEach — dùng LLM mô phỏng dialogue sinh viên để đào tạo giáo viên. Lu & Wang (2024) phát hiện profile-based generative students có thể phản ánh performance thực của sinh viên trong MCQ. Jin et al. (2025) đề xuất TeachTune — framework sinh dialogues sự phạm với student profiles đa dạng.

EducationQ kế thừa insight từ các nghiên cứu này nhưng đi theo hướng khác: thay vì tạo student profiles đa dạng, framework giữ **student cố định** (Llama 70B) để cô lập và đo lường hiệu quả giảng dạy của teacher. Đây là lựa chọn thiết kế quan trọng mà chúng ta sẽ phân tích sâu hơn.

3. Nền tảng lý thuyết giáo dục — Bốn trụ cột

Một câu hỏi tự nhiên: "Tại sao cần kéo lý thuyết giáo dục vào? Sao không chỉ cho LLM dạy rồi đo kết quả?"
Câu trả lời: vì không có lý thuyết, ta không biết **thiết kế framework thế nào**. Mỗi lý thuyết giáo dục trong paper ánh xạ trực tiếp vào một quyết định thiết kế cụ thể. Đây không phải "trang trí" — đây là nguyên lý thiết kế.

3.1 Zone of Proximal Development (ZPD) — Vygotsky, 1978

Khái niệm: Mỗi người học có hai mức — mức phát triển thực tế (actual development level) là những gì tự làm được, và mức phát triển tiềm năng (potential development level) là những gì đạt được với hướng dẫn phù hợp. Khoảng giữa hai mức này là ZPD — vùng mà dạy học hiệu quả nhất xảy ra.

Tại sao quan trọng: Dạy ở dưới ZPD (quá dễ) = lãng phí — student đã biết. Dạy ở trên ZPD (quá khó) = vô hiệu — student không tiếp nhận được. Dạy đúng trong ZPD = hiệu quả tối đa.

Áp dụng trong framework: Pre-test đo "actual development level" — student agent đạt 47.73% baseline. Interaction (5 rounds) là nơi teacher hoạt động trong ZPD. Post-test đo mức đạt được. ALG (chênh lệch accuracy) chính là thước đo hiệu quả hoạt động trong ZPD. Contribution #1 của paper tuyên bố rõ: "A theoretical framework integrating formative assessment and Vygotsky's learning theory to evaluate educational LLMs."

Bằng chứng từ kết quả (Section 7.4): Hầu hết model dạy tốt nhất ở mức dễ (prior accuracy ~0.8) — chỉ "reinforcing already known zone." Nhưng Llama 70B có pattern khác: peak performance ở mức khó trung bình (prior accuracy ~0.5), chiếm 27% tổng ALG. Điều này nghĩa là Llama 70B hoạt động hiệu quả nhất *đúng trong ZPD* — scaffolding cho khái niệm thách thức vừa phải thay vì ôn lại kiến thức đã biết.

3.2 Scaffolding — Wood, Bruner & Ross, 1976

Khái niệm: Scaffolding (giàn giáo) là chiến lược dạy học trong đó người có kinh nghiệm cung cấp hỗ trợ tạm thời, có cấu trúc, thích ứng theo năng lực người học. Ba đặc điểm: (1) hỗ trợ chỉ ở mức cần thiết — không làm thay, (2) gỡ bỏ dần khi người học tiến bộ, (3) mục tiêu là người học tự đứng vững.

Áp dụng — Content Boundary Design (Section 4.8): Đây là thiết kế sáng tạo nhất và quan trọng nhất của framework. Ba ràng buộc kỹ thuật:

(a) **Teacher không thể truy cập answer options.** Khi gọi API cho TeacherLLM.generate_question(), input chỉ bao gồm: nội dung câu hỏi (raw text, KHÔNG có A/B/C/D), student reasoning, và phán đoán đúng/sai. Options bị strip khỏi input ở mức kỹ thuật. Teacher biết student sai nhưng không biết đáp án đúng là gì trong các lựa chọn.

(b) **Student không biết kết quả pre-test** trong quá trình dialogue. Student chỉ học qua tương tác với teacher — không có "check đáp án."

(c) **Student giữ toàn bộ câu hỏi + options** — có thể "experience association" khi teacher gợi ý.

Tại sao asymmetry này? Teacher biết đúng/sai nhưng không biết options → phải dẫn dắt qua khái niệm, không qua lựa chọn cụ thể. Student biết options nhưng không biết mình sai → phải học qua tương tác,

không qua "check đáp án." Đây chính là scaffolding: gợi ý thay vì cho đáp án.

Case study — Question 240 (Business): Llama 70B hỏi "Can you explain why you chose to divide..." → student giải thích → teacher hỏi tiếp "could it be an approximation? How might this affect your calculation?" → student nhận ra rounding error → tự sửa từ option F sang option E (đúng). Teacher KHÔNG BAO GIỜ nói "đáp án là E." Trong khi đó, Llama 405B chỉ hỏi "Can you calculate..." — drill lặp lại — student không phát hiện lỗi. **Model lớn hơn 5.8 lần nhưng scaffolding kém hơn.**

3.3 Bloom's Taxonomy — Bloom (1956), Krathwohl (2002)

Khái niệm: Phân loại 6 mức nhận thức: Remember (nhớ) → Understand (hiểu) → Apply (áp dụng) → Analyze (phân tích) → Evaluate (đánh giá) → Create (sáng tạo). Giáo viên giỏi đặt câu hỏi đa dạng qua nhiều mức — không chỉ ở mức "nhớ."

Áp dụng: Evaluator agent đánh giá "Cognitive Level" và "Knowledge Dimension" — 2 trong 17 chiều. Câu hỏi Teacher-Centric bao gồm: Question Relevance, **Cognitive Level**, **Knowledge Dimension**, Question Diversity, Scaffolding Progression, Metacognitive Promotion. Bloom cung cấp thước đo để đánh giá chất lượng câu hỏi mà teacher đặt ra.

Expert case studies xác nhận Llama 70B "employed guidance across different cognitive levels" — di chuyển từ "can you explain why" (Understand/Analyze) → "how might this affect" (Evaluate) → "what implications" (Create/Evaluate). Đây là progression qua Bloom levels — trong khi 405B chỉ ở mức "procedural practice" (Apply, lặp lại).

3.4 Informal Formative Assessment (IFA) — Ruiz-Primo & Furtak, 2007

Khái niệm: Có hai loại đánh giá: summative (thi cuối kỳ — đo kết quả) và formative (đánh giá liên tục — phát hiện lỗ hổng, điều chỉnh cách dạy). IFA là dạng phổ biến nhất trong lớp học: xảy ra tự nhiên khi giáo viên hỏi → nghe → đánh giá → phản hồi → hỏi tiếp. Ranh giới giữa "dạy" và "đánh giá" mờ đi — giáo viên vừa dạy vừa đánh giá đồng thời.

Đây là lý thuyết trung tâm. Toàn bộ pipeline EducationQ mô phỏng IFA: Pre-test = summative assessment ban đầu. 5 rounds dialogue = IFA. Post-test = summative assessment cuối. ALG = thước đo hiệu quả IFA.

3.5 Bốn lý thuyết liên kết thành hệ thống

ZPD trả lời "dạy ở đâu?" — xác định vùng học tập lý tưởng. IFA trả lời "đánh giá bằng cơ chế nào?" — đánh giá liên tục để xác định vị trí student trong ZPD. Scaffolding trả lời "hỗ trợ thế nào?" — gợi ý, không cho đáp án. Bloom trả lời "đo chất lượng bằng gì?" — thước đo đa chiều cho câu hỏi và hướng dẫn. Bốn câu hỏi thiết kế, bốn lý thuyết, bốn thành phần kỹ thuật.

4. Kiến trúc EducationQ — Ba tác tử, ba pha

4.1 Tổng quan kiến trúc

EducationQ sử dụng hệ thống ba tác tử (triadic system): Student Agent (người học), Teacher Agent (giáo viên — LLM đang bị đánh giá), và Evaluator Agent (giám khảo). Ba tác tử tương tác qua pipeline ba pha: Pre-Test → Interaction → Post-Test.

Đây KHÔNG phải agent orchestration (kiểu LangGraph, CrewAI). Khác biệt cốt lõi: flow cố định (không có routing động), agents ngang hàng (không có orchestrator trung tâm), mục đích là mô phỏng kịch bản (simulation) chứ không phải giải task (task completion). Paper chọn flow cố định vì cần controlled experiment — mọi teacher phải được đánh giá trong cùng điều kiện.

4.2 Student Agent — Llama 3.1 70B Instruct

Vai trò: Mô phỏng hành vi học sinh thực — phân tích vấn đề, diễn đạt suy nghĩ, thể hiện sự không chắc chắn.

Implementation (StudentLLM class): Temperature 0.0 (deterministic — reproducibility). Max tokens: dialogue 1,024, test 2,048. Soft token limit dialogue: 150 tokens. Token rerun threshold: 80% (nếu response > 80% max VÀ > soft limit → retry, tối đa 5 lần). Hai methods chính: `answer_question()` (dialogue) và `take_test()` (pre/post-test).

System prompt: "You are a student focusing on [CATEGORY]. Analyze the question carefully, explain your thought process ([TOKEN_LIMIT] tokens or less), and try to apply the concepts you've learned to solve problems. If you're unsure, express your uncertainty and explain your reasoning."

Tại sao chọn Llama 70B? Ba lý do chiến lược: (1) Open-source → ai cũng có thể chạy lại (reproducibility), (2) IFEval 86.96 → tuân thủ soft token limit tốt (instruction-following mạnh), (3) GPQA Diamond baseline 46.97% → đủ "khó" để có room for improvement nhưng không quá thấp. Nếu student quá giỏi (>80%), improvement space quá hẹp; nếu quá yếu (<20%), teacher không thể dạy hiệu quả trong 5 rounds.

Tại sao student cố định? Đây là controlled experiment — biến cần đo là teacher performance, nên student phải là hằng số. Nếu thay đổi student theo experiment, ta không phân biệt được improvement do teacher hay do student. Ablation study (Table 2) kiểm chứng: đổi sang Qwen 72B hoặc Mistral Nemo → ranking giữa teachers hầu như không đổi → method cô lập teacher performance hiệu quả.

4.3 Teacher Agent — Model đang bị đánh giá

Vai trò: Đánh giá động quá trình tư duy student, sử dụng probing questions, cung cấp phản hồi, sửa lỗi khi cần — tất cả mà KHÔNG tiết lộ đáp án.

Implementation (TeacherLLM class): Temperature 0.0. Max tokens: 1,024. Soft token limit: 150 tokens/question (thực tế trung bình 73.6). `use_few_shot`: false (default). Method chính: `generate_question()`.

Input format: Teacher nhận pre-test info gồm: Question ID, Question Text (KHÔNG có options), Student's Reasoning, Student's Answer, và Correctness ("Correct." hoặc "Incorrect."). Teacher biết student sai/đúng nhưng KHÔNG biết đáp án đúng là gì trong các lựa chọn. Đây là ràng buộc kỹ thuật, không chỉ prompt instruction — options bị strip khỏi input trước khi gọi API.

Prompt generation: Mỗi round, prompt cuối là: "Generate the round [N] question ([TOKEN_LIMIT] tokens or less) to promote better understanding." API mapping: teacher turns → role: assistant, student turns → role: user.

4.4 Evaluator Agent — GPT-4o

Vai trò: Chuyên gia đánh giá giáo dục — validate dialogue, tính accuracy, chấm điểm qua 17 chiều, so sánh giữa hai teachers.

Implementation (EvaluatorLLM class): Temperature 0.0. Max tokens: 4,096. Output: Structured JSON schema (enforce qua API response_format). Ba methods ứng với ba góc phân tích:

(1) `over_interaction_analysis()` — Holistic Interaction: input là full dialogue + pre-test, đánh giá 5 chiều (Assessment, Questioning, Feedback, Instructional Adaptation, Learning Objective Achievement).

(2) `teacher_questions_analysis()` — Teacher-Centric: input CHỈ là câu hỏi của teacher, đánh giá 6 chiều (Question Relevance, Cognitive Level, Knowledge Dimension, Question Diversity, Scaffolding Progression, Metacognitive Promotion).

(3) `student_responses_analysis()` — Student-Centric: input CHỈ là câu trả lời student, đánh giá 6 chiều (Response Relevance, Cognitive Level Demo, Knowledge Dimension Integration, Response Diversity, Elaboration Progression, Metacognitive Reflection).

Mỗi chiều gồm analysis (văn bản phân tích) + score (1-10). Khi so sánh hai teachers, output thêm verdict (comparative analysis + choice A/B/Tie), với teachers được ẩn danh thành teacher_a/teacher_b.

4.5 Pipeline ba pha — Chi tiết kỹ thuật

Pha 1 — Pre-Test: Student làm bài theo official protocol (MMLU-Pro: CoT + 5-shot; GPQA Diamond: CoT 0-shot). Response format: reasoning + "The answer is (X)". Evaluator parse đáp án, tính accuracy baseline.

Pha 2 — Interaction (IFA): 5 rounds per question. Mỗi round: teacher generate question → student respond. Teacher nhận full dialogue history + pre-test results. Student nhận full dialogue history + system message (nhưng KHÔNG có pre-test correctness).

Ablation on parameters (Section 4.9): Tăng token 150→250 → no significant gains. Giảm 150→70-100 → degraded performance. Tăng rounds 5→10 (token halved) → increased cost, no improvement. Kết luận: 5 rounds × 150 tokens là sweet spot. Thực tế: teacher trung bình 73.6 tokens/turn, student 260 tokens/turn.

Pha 3 — Post-Test: Student làm lại bài, context window bao gồm: pre-test reasoning + toàn bộ 5 rounds dialogue. Cùng protocol/parameter với pre-test. Evaluator tính accuracy mới → ALG = post - pre.

4.6 Data Quality Assurance

Hai cơ chế retry tự động: (1) Empty Response Detection: token count = 0 → retry. (2) Anomalous Output Detection: token count > 80% max limit VÀ > recommended limit → retry. Max 5 retries/question. Tất cả trigger cases review thủ công. API error recovery: initial delay 10s, max delay 320s, max retries 5. Parallel processing: max 5 concurrent tasks, ThreadPoolExecutor, progress tracking.

5. Dữ liệu đánh giá — 1.498 câu hỏi

Dataset gồm 1,498 câu hỏi từ hai nguồn:

GPQA Diamond (198 câu): Expert-validated, graduate/PhD level. Đặc biệt: non-experts đạt dưới 33% — câu hỏi thực sự khó, không thể "đoán mò." Ba disciplines: Physics (86), Chemistry (93), Biology (19).

MMLU-Pro Stratified (1,300 câu): Subset mới tự xây dựng từ MMLU-Pro (12,032 câu). Lý do: MMLU-Pro gốc phân bố lệch — nhiều câu dễ, ít câu khó, một số môn nhiều hơn. EducationQ cần balanced representation.

Quy trình: (1) tính mean accuracy top 10 models cho mỗi câu → difficulty rating, (2) loại category "other" → 13 disciplines, (3) chia 10 mức khó (10% intervals), (4) sample 10 câu đầu từ mỗi (discipline × difficulty). Kết quả: $13 \times 10 \times 10 = 1,300$ câu, phân bố đều hoàn toàn.

13 disciplines: Business, Law, Psychology, Biology, Chemistry, History, Health, Economics, Math, Physics, Engineering, Philosophy, Computer Science.

Baseline accuracy: 47.73% với Llama 70B — đủ room cho improvement.

6. Hệ thống đo lường — Bốn thước đo

ALG (Absolute Learning Gain): $ACC_{post} - ACC_{pre}$. Metric chính. Đo trực tiếp "student tiến bộ bao nhiêu sau khi được dạy."

PNIR (Positive-Negative Impact Ratio): $N_{negative} / N_{positive}$ (thấp = tốt). Đo tính nhất quán — có bao nhiêu trường hợp "dạy ngược" (student từ đúng → sai)? Llama 70B: 0.18 (36 neg / 200 pos). Phi-3.5-mini: 0.69 — gần 70% negative so với positive.

CSS (Cross-Subject Stability): Standard deviation của learning gains theo subject (thấp = tốt). Đo "dạy đều các môn không?" Gemini 1.5 Pro: 0.030 (đồng đều nhất). Phi-3.5-mini: 0.172 (rất lệch).

UIC (Unique Improvement Count): Số câu mà CHỈ model đó đạt improvement — đo năng lực chuyên biệt. Llama 70B và Gemini cùng 37 UIC — pattern khác: Llama cân bằng ($\sigma=0.036$), Gemini tập trung ($\sigma=0.056$, peak 21% Biology).

7. Kết quả thực nghiệm — Phân tích sâu

7.1 Bảng xếp hạng tổng thể

#	Model	Params	ALG	PNIR	CSS	UIC
1	Llama 3.1 70B Instruct	70B	+11.01%	0.18	0.041	37
2	Gemini 1.5 Pro 002	—	+7.48%	0.40	0.030	37
3	Llama 3.1 405B Instruct	405B	+6.14%	0.28	0.045	9
4	OpenAI o1-mini	—	+5.84%	0.25	0.051	7
5	Qwen 2.5 72B Instruct	72B	+5.41%	0.33	0.054	7
6	Llama 3.1 8B Instruct	8B	+4.87%	0.40	0.051	13
7	Hermes 3 Llama 3.1 70B	70B	+4.14%	0.39	0.051	6
8	Mistral Nemo	12B	+3.94%	0.44	0.058	12
9	Claude 3.5 Sonnet	—	+3.81%	0.30	0.059	5
10	WizardLM-2 8x22B	176B	+3.67%	0.34	0.047	2
11	DeepSeek V2.5	—	+3.27%	0.46	0.051	3
12	Command R 08-2024	—	+2.94%	0.53	0.057	7
13	GPT-4o-mini	—	+2.44%	0.40	0.085	2
14	Phi-3.5-mini Instruct	3.8B	+1.20%	0.69	0.172	4

7.2 Phân tích: Tại sao Llama 70B thắng?

Đây là câu hỏi trung tâm và paper trả lời bằng cả phương pháp thống kê lẫn case study định tính.

Phân tích thống kê (Section 7.7): Paper chạy logistic regression và Random Forest (1000 trees, accuracy=0.769, AUC=0.775) trên 148 UIC cases + 148 control dialogues. Kết quả: **questioning quality** là predictor mạnh nhất cho Llama 70B (Exp(B)=32.864, p=0.043; Mean dropout loss 0.363). Đối với Gemini 1.5 Pro, predictor mạnh nhất là **feedback quality** (Exp(B)=5227.342, p=0.019; Mean dropout loss 0.344).

Nói cách khác: **hai model top dùng chiến lược khác nhau để thành công**. Llama 70B thắng nhờ đặt câu hỏi giỏi. Gemini thắng nhờ phản hồi giỏi. Cả hai đều là teaching skills, không phải knowledge depth.

Expert case studies (Section 8.1): Chuyên gia xác nhận Llama 70B sử dụng "carefully constructed question sequences and metacognitive support scaffolding" — chuỗi câu hỏi được xây dựng cẩn thận, kết hợp với hỗ trợ metacognitive (giúp student suy nghĩ về cách mình suy nghĩ).

Cụ thể, Llama 70B di chuyển qua nhiều mức Bloom: "can you explain why" (Understand) → "how might this affect" (Analyze/Evaluate) → "what implications would it have" (Evaluate/Create). Đây là progressive questioning — tăng dần mức nhận thức.

Trong khi đó, Llama 405B dù có nhiều kiến thức hơn, "emphasized repetitive practice over conceptual understanding" — lặp lại drill thay vì xây dựng hiểu biết khái niệm.

Insight cốt lõi: Model lớn hơn BIẾT nhiều hơn nhưng DÙNG kiến thức kém hơn trong context giảng dạy. 405B có thể trả lời đúng câu hỏi mà 70B sai — nhưng 70B dẫn dắt student tìm ra đáp án hiệu quả hơn 405B. Đây là bằng chứng mạnh nhất cho thesis "scale $\neq$ teaching."

7.3 Chuyên môn theo môn học

Knowledge-intensive: Llama 70B thống trị — Health +24%, Psychology +18%, Philosophy +19%, History +14%. Đây là các môn cần dẫn dắt qua khái niệm, giải thích, và xây dựng hiểu biết — đúng thể mạnh questioning strategy của Llama.

Reasoning-intensive: o1-mini thống trị — Physics +8.6%, Math +9%. Đây là các môn cần suy luận logic, giải bước — o1-mini (chuyên về reasoning) phù hợp.

Applied disciplines: Gemini 1.5 Pro — Business +8%, Economics +9%. Các môn ứng dụng cần kết nối lý thuyết với thực tế — phù hợp adaptive feedback strategy.

7.4 Robustness — Framework có đáng tin không?

Paper report nhiều kiểm tra: Cross-dataset consistency $r=0.871$ ($p < 0.001$). Subject-specific: Physics $r=0.904$, Chemistry $r=0.917$. Test-retest (Table 3): mean variance = 0.00832. Đây là mức ổn định rất cao cho evaluation framework — ranking giữa các model gần như không đổi khi chạy lại.

8. Kiểm chứng bởi chuyên gia

Đánh giá tự động là cần thiết để scale, nhưng liệu GPT-4o evaluator có đáng tin? Paper kiểm chứng bằng human experts.

Quy trình: 7 giáo viên có chứng chỉ + 1 tác giả đánh giá 50 cặp dialogues (mỗi cặp: 1 có learning gain + 1 không). Teacher identities ẩn danh. So sánh majority preference của experts vs. evaluator agent verdict.

Kết quả: 78% agreement (39/50 cases). Teachers có learning gain nhận trung bình 7.38/10 từ experts; control group 6.41/10. Quan trọng: **không reviewer nào phát hiện teacher tiết lộ đáp án** — content boundary design hoạt động.

Ý nghĩa: 78% trên nội dung chuyên sâu MMLU-Pro (nhiều môn khó) là impressive. 50 pairs đại diện ~40% khoảng cách performance giữa best/worst teacher → mẫu đại diện. Điều này confirm rằng automated evaluation correlates tốt với human judgment — framework đáng tin cậy.

9. Giới hạn & hướng phát triển

Kịch bản đơn giản: 1-on-1 IFA — không capture dynamics lớp học nhiều học sinh, không đo quản lý nhóm. Thực tế: giáo viên dạy 30-40 học sinh cùng lúc, mỗi người ở mức khác nhau.

Giới hạn round: 5 rounds cố định — không so sánh được teaching efficiency (model nào cần ít round hơn). Có thể model A dạy tốt hơn model B nhưng cần 10 rounds — EducationQ không capture được.

Student modeling: Chỉ 1 student profile cố định — không simulate diverse age groups, cognitive levels, backgrounds, motivations. Sinh viên thực có personality, prior knowledge, motivation khác nhau.

Content level: Chỉ graduate/PhD level — không đánh giá dạy K-12. Teaching K-12 rất khác graduate: cần ngôn ngữ đơn giản hơn, nhiều ví dụ trực quan hơn, kiên nhẫn hơn.

Model selection: Không include nhiều version trong cùng series → không track teaching capability evolution. Không có multimodal models hoặc specialized educational models.

Content moderation: OpenAI models (o1-mini, GPT-4o-mini) trả về NoneType cho câu hỏi Vietnam War (Question 5048) — content policies tạo gap trong đánh giá các chủ đề nhạy cảm.

10. Tổng kết & Ý nghĩa

10.1 Hai insight chính

Insight 1 — Scale $\neq$ Teaching: Model nhỏ hơn (open-source) có thể dạy tốt hơn model lớn (commercial) thông qua chiến lược sư phạm hiệu quả. Llama 70B dạy gấp $\sim 1.8\times$ so với Llama 405B. Điều này thách thức giả định phổ biến rằng model lớn hơn = giỏi hơn ở mọi thứ.

Insight 2 — Strategy $>$ Knowledge: LLMs-as-Teachers thành công qua tương tác có mục tiêu, phương pháp dạy thích ứng — không phải qua "kho kiến thức rộng hơn." Llama 70B thắng nhờ questioning, Gemini thắng nhờ feedback — cả hai đều là teaching skills.

10.2 Implications

Cho phát triển educational AI: Cần tối ưu chuyên biệt cho pedagogical effectiveness thay vì chỉ general scaling. Next-gen educational AI cần targeted enhancement cho specific teaching skills.

Cho đánh giá LLM: Traditional metrics (MMLU, GPQA scores) dự đoán kém teaching effectiveness. Cần framework chuyên biệt như EducationQ cho educational AI development.

Cho triển khai thực tế: Nếu đang chọn model cho ứng dụng giáo dục, KHÔNG nên chọn dựa trên MMLU score. Cần đánh giá bằng framework đo teaching capability — hoặc ít nhất, cân nhắc rằng model nhỏ hơn có thể phù hợp hơn.

10.3 Contribution tổng kết

Paper đóng góp: (1) Theoretical framework tích hợp formative assessment + ZPD để đánh giá educational LLMs. (2) Multi-agent dialogue methodology cho simulation và analysis teaching interactions. (3) High-quality educational dataset gồm standardized tests và re-annotated teacher-student dialogues (14,980 five-round interactions). (4) Vast empirical evaluation chứng minh significant student learning gains (lên tới +12.63% trên GPQA Diamond).

Thông điệp cuối cùng: EducationQ không chỉ là một benchmark — nó là lời kêu gọi thay đổi cách chúng ta nghĩ về LLM trong giáo dục. Thay vì hỏi "model này biết bao nhiêu?", hãy hỏi "model này DẠY tốt thế nào?" — và EducationQ cho chúng ta công cụ để trả lời câu hỏi đó.