

Motivation, Educational Grounding và Tổng quan EducationQ

Vì sao paper EducationQ tồn tại?

Khuê Lê Trần Minh

1 Giới thiệu

Mô hình ngôn ngữ lớn (LLM) đang nhanh chóng được đưa vào giáo dục — từ trợ giảng ảo đến hệ thống gia sư cá nhân hóa. Song song với làn sóng ứng dụng đó là một câu hỏi nền tảng nhưng thường bị bỏ qua: làm sao biết một mô hình có thực sự *dạy* tốt hay không? Phần lớn cách đánh giá hiện nay đo xem mô hình *biết* bao nhiêu — nó trả lời đúng được bao nhiêu câu — chứ không đo xem nó giúp người học tiến bộ tới đâu.

Đây chính là khoảng trống mà paper EducationQ [1] (Shi và cộng sự, ACL 2025) nhắm tới. Báo cáo này đi tìm lời đáp cho một câu hỏi xuyên suốt — **vì sao paper EducationQ tồn tại?** — bằng cách lần lượt xem xét động lực thúc đẩy nó, nền tảng lý thuyết giáo dục mà nó dựa vào, thiết kế tổng thể của khung đánh giá, hai phát hiện cốt lõi, cũng như cách cộng đồng đón nhận và một vài nhận xét phản biện. Mạch lập luận bắt đầu từ một quan sát tưởng như hiển nhiên nhưng lại là gốc rễ của vấn đề: giỏi trả lời và giỏi giảng dạy không phải là một.

2 Motivation — Vì sao paper tồn tại


2.1 Câu chuyện mở đầu: *knowing* không phải *teaching*

Hãy bắt đầu bằng một câu hỏi tưởng như ngây thơ: *nếu một mô hình ngôn ngữ lớn (LLM) đạt 90% trên MMLU, liệu nó có dạy cho một sinh viên hiểu bài hay không?* Trực giác thông thường trả lời “có” — một hệ thống biết nhiều thì hẳn phải dạy giỏi. Nhưng trực giác đó trộn lẫn hai năng lực vốn rất khác nhau: *biết* (knowing — trả lời đúng một câu hỏi) và *dạy* (teaching — khiến người khác tự đi tới chỗ hiểu). Một chuyên gia có thể giải bài toán trong vài giây nhưng hoàn toàn bất lực khi phải dẫn dắt một người mới bắt đầu; ngược lại, một giáo viên giỏi đôi khi không phải người giỏi nhất về chuyên môn, mà là người biết *đặt câu hỏi đúng lúc*.

EducationQ [1] xây dựng toàn bộ lập luận trên ranh giới này. Luận đề trung tâm của paper — và cũng là điểm khởi đầu cho phần báo cáo này — là: năng lực trả lời và năng lực giảng dạy là hai chiều *có thể tách rời*, và hệ thống đánh giá hiện tại chỉ đo chiều thứ nhất. Đây là một giả định mạnh; chúng tôi tạm chấp nhận nó để theo dõi mạch lập luận, và sẽ quay lại kiểm chứng bằng bằng chứng thực nghiệm ở Mục 2.6.

2.2 Ba giai đoạn tiến hóa của LLM trong giáo dục

Để thấy EducationQ đứng ở đâu, paper phác họa quá trình LLM bước vào giáo dục qua ba giai đoạn (Hình 1).



Hình 1: Ba giai đoạn tiến hóa của LLM trong giáo dục: từ tác vụ tổng quát đơn lượt, sang tác vụ giáo dục đơn lượt, đến kịch bản động đa tác tử mà EducationQ đề xuất. Nguồn: Shi và cộng sự, 2025, Figure 1.

Giai đoạn A — Tác vụ tổng quát, đơn lượt. Các benchmark kinh điển như MMLU [2], GPQA [3] hay MathChat ở dạng câu hỏi đơn vận hành theo cơ chế: một câu hỏi → một câu trả lời → chấm đúng/sai. LLM đóng vai *thí sinh*. Hoàn toàn không có tương tác.

Giai đoạn B — Tác vụ giáo dục, đơn lượt. LLM bắt đầu đảm nhận các vai mang tính giáo dục — sinh câu hỏi trắc nghiệm, sinh câu hỏi gợi mở kiểu Socratic, chấm bài tự động, phản hồi cho bài đánh giá. Nhưng mỗi tác vụ chỉ kiểm tra *một* năng lực giáo dục rời rạc, tách khỏi một cuộc hội thoại dạy học thực sự.

Giai đoạn C — Kịch bản giáo dục động, đa tác tử (EducationQ). Lần đầu tiên, năng lực dạy học được đánh giá một cách *tổng hợp*: trong một cuộc hội thoại nhiều lượt, mô hình phải đồng thời đặt câu hỏi, đánh giá mức hiểu của học sinh, đưa phản hồi và điều chỉnh chiến lược. Bước nhảy từ B sang C mới là điểm cốt lõi: lớp học thật không phải chuỗi tác vụ rời rạc, mà là một chu trình khép kín — giáo viên liên tục đọc phản hồi của học sinh để quyết định khi nào gợi ý, khi nào để học sinh tự khám phá. Không một benchmark đơn lượt nào nắm bắt được chu trình này.

2.3 Ba paradigm đánh giá hiện tại và hạn chế

Vì sao không paradigm đánh giá nào hiện có lấp được khoảng trống trên? Bảng 1 tóm tắt ba hướng tiếp cận phổ biến nhất.

Paradigm **câu hỏi đóng** [2], [3] mạnh về tự động hóa và khả năng tái lập, nhưng về bản chất chỉ trả lời câu hỏi “mô hình *biết* gì”, không phải “mô hình *dạy* giỏi đến đâu”. Paradigm **sở thích con người** [4] (MT-Bench, Chatbot Arena) đưa yếu tố tương tác và đánh giá của con người vào, nhưng tối ưu sai mục tiêu: nó đo sự hài lòng tổng quát của người dùng, trong khi một phản hồi hiệu quả về mặt sư phạm đôi khi lại khiến người học “khó chịu” vì buộc phải tự suy nghĩ. Paradigm **hội thoại nhiều lượt** [5] (MathChat) tiến gần nhất — và chính phát hiện của MathChat rằng các mô hình “chật vật khi phải suy luận bền bỉ qua nhiều lượt” đã gợi ý

Bảng 1: Ba paradigm đánh giá LLM hiện tại và hạn chế đối với bối cảnh giáo dục.

Paradigm	Đại diện	Hạn chế cho giáo dục
Câu hỏi đóng	MMLU, GPQA	Biến LLM thành “thí sinh”; không có tương tác, không đo được vai trò người dạy.
Sở thích con người	MT-Bench, Chatbot Arena	Đo “mức hài lòng” của người dùng; một câu trả lời ẩn tượng không đồng nghĩa với một bài giảng hiệu quả.
Hội thoại nhiều lượt	MathChat	Có tương tác nhưng đo <i>khả năng suy luận</i> của mô hình, thiếu cơ chế gợi ra và đo lường hành vi <i>dạy học</i> .

rằng đánh giá đa lượt mới bộc lộ điểm yếu thật. Nhưng MathChat vẫn đo năng lực suy luận, không có vai trò người dạy rõ ràng, không có pre-test/post-test, không có giám khảo chuyên về sư phạm.

2.4 Tuyên bố khoảng trống

Ba paradigm, ba góc nhìn, nhưng cùng một điểm mù: không paradigm nào đặt LLM vào vai trò *giáo viên* và đo *kết quả học tập* mà nó tạo ra.

Khoảng trống đánh giá

Các benchmark hiện tại “ưu tiên việc ghi nhớ kiến thức hơn là sư phạm tương tác”. Sự khác biệt lớn về hiệu quả dạy học giữa các mô hình cũng “cho thấy sự bất cập của các metric LLM truyền thống trong việc dự báo hiệu quả giảng dạy, nhấn mạnh nhu cầu cấp thiết về những khung đánh giá chuyên biệt, dựa trên tương tác như EducationQ” [1].

2.5 Năm chức năng giảng dạy bị bỏ lỡ

Khoảng trống trên không chỉ là vấn đề kỹ thuật của benchmark; nó bỏ lỡ những chức năng cốt lõi mà nghiên cứu giáo dục đã xác lập từ lâu. Paper viện dẫn năm chức năng:

- (1) Dẫn dắt quá trình học [6];
- (2) Tạo điều kiện xây dựng kiến thức [7];
- (3) Tổ chức hoạt động giáo dục [8];
- (4) Cung cấp phản hồi cá nhân hóa [9];
- (5) Scaffolding để phát triển kỹ năng [10].

Không một benchmark câu hỏi đóng nào chạm tới bất kỳ chức năng nào trong số này. Chính khoảng cách giữa “điều ta đo được” và “điều thực sự làm nên một người dạy giỏi” là lý do tồn tại của EducationQ.

2.6 Phát hiện phản trực giác

Lập luận trên sẽ chỉ là suy đoán nếu không có bằng chứng. Và bằng chứng thuyết phục nhất của paper lại đến từ một kết quả đi ngược trực giác về quy mô mô hình.

Quy mô lớn hơn, dạy kém hơn

Llama 3.1 70B Instruct (mã nguồn mở) đạt mức tăng học tập tuyệt đối ALG +11.01%, vượt xa Llama 3.1 405B (+6.14%) — dù mô hình sau lớn hơn khoảng $5.8\times$ về số tham số — và vượt cả Claude 3.5 Sonnet (xếp hạng 9/14) [1].

Phát hiện này không thể bộc lộ qua bất kỳ benchmark câu hỏi đóng nào: trên thang đo “biết”, mô hình lớn hơn gần như luôn nhỉnh hơn. Chỉ khi đặt vào vai người dạy và đo kết quả học của học sinh, sự đảo ngược mới xuất hiện. Đây chính là bằng chứng mời cho luận đề *knowing* $\neq$ *teaching* ở Mục 2.1.

Tuy vậy, cũng cần một nhận xét phản biện ngay tại đây: con số ALG được đo khi học sinh làm lại bài *với toàn bộ lịch sử hội thoại nằm trong ngữ cảnh*. Vì thế vẫn tồn tại một câu hỏi treo — mức cải thiện phản ánh *học thật* hay chỉ là việc mô hình cung cấp thông tin tốt hơn ngay trong ngữ cảnh? Cách định nghĩa và tính toán ALG cùng phân tích kết quả chi tiết nằm ngoài phạm vi phần này; ở đây chúng tôi chỉ dùng con số này như động lực, và ghi nhận đây là một điểm đáng tiếp tục mổ xẻ trong phần đánh giá của nhóm.

3 Nền tảng lý thuyết giáo dục

3.1 Tại sao cần lý thuyết?

Một câu hỏi tự nhiên: tại sao không để LLM dạy rồi đo kết quả, mà phải viện đến Vygotsky hay Bloom? Câu trả lời là: không có lý thuyết thì không biết thiết kế khung như thế nào. Nếu không có khái niệm vùng phát triển, ta không biết vì sao cần pre-test và post-test; không có scaffolding, ta không biết vì sao phải cấm giáo viên tiết lộ đáp án; không có Bloom, ta không có chiều nào để đánh giá chất lượng câu hỏi; không có đánh giá quá trình, ta không biết giao thức tương tác đang mô phỏng điều gì. Bốn lý thuyết dưới đây vì thế không phải lớp “trang trí học thuật”, mà là *nguyên lý thiết kế* trực tiếp của EducationQ.

3.2 Vùng Phát triển Gần (ZPD)

Vygotsky [11] định nghĩa ZPD (Zone of Proximal Development) là khoảng cách giữa mức người học tự làm được và mức làm được khi có hướng dẫn. Dạy dưới vùng này thì lãng phí (quá dễ), dạy trên vùng này thì vô hiệu (quá khó); dạy *trong* vùng cho hiệu quả tối đa. EducationQ hiện thực hóa ý tưởng này một cách trực tiếp: pre-test đo mức hiện tại của người học, nằm vòng hội thoại là không gian giáo viên hoạt động trong ZPD, và post-test đo mức đạt được sau hỗ trợ.

3.3 Scaffolding

Wood, Bruner và Ross [10] mô tả *scaffolding* (giàn giáo nhận thức) là sự hỗ trợ tạm thời, có cấu trúc, được gỡ bỏ dần khi người học tiến bộ, với mục tiêu cuối là để người học tự đứng vững.

Đây là lý thuyết dẫn tới chi tiết thiết kế sáng tạo nhất của EducationQ — *thiết kế ranh giới nội dung* (content boundary): giáo viên biết học sinh trả lời đúng hay sai nhưng *không* được nhìn thấy các lựa chọn đáp án, nên buộc phải dẫn dắt qua khái niệm thay vì chỉ ra “đáp án là C”. Cơ chế kỹ thuật cụ thể của ràng buộc này không bàn sâu ở đây; ta chỉ nhấn mạnh nó bắt nguồn trực tiếp từ nguyên lý scaffolding.

3.4 Thang phân loại Bloom


Thang Bloom [12], được Krathwohl [13] cập nhật, sắp xếp nhận thức theo sáu mức từ thấp đến cao: Nhớ → Hiểu → Vận dụng → Phân tích → Đánh giá → Sáng tạo. Thang này cung cấp *chiều đo* cho chất lượng câu hỏi mà giáo viên đặt ra: một chuỗi câu hỏi tốt sẽ nâng dần người học lên các mức nhận thức cao hơn, thay vì lặp lại ở mức “vận dụng”. Trong EducationQ, Bloom là cơ sở cho một số trong các chiều đánh giá định tính (chi tiết bộ chiều này nằm ngoài phạm vi phần này).

3.5 Đánh giá quá trình phi chính thức (IFA)

Ruiz-Primo và Furtak [14] phân biệt đánh giá tổng kết (summative — đo kết quả cuối) với đánh giá quá trình (formative — liên tục phát hiện lỗ hổng và điều chỉnh). *Đánh giá quá trình phi chính thức* (IFA) là dạng phổ biến nhất trong lớp học, diễn ra tự nhiên ngay trong hội thoại, khiến ranh giới giữa “dạy” và “đánh giá” mờ đi [15]. Đây là lý thuyết trung tâm: toàn bộ pipeline của EducationQ chính là một vòng IFA — pre-test là đánh giá ban đầu, năm vòng hội thoại là IFA, post-test là đánh giá cuối, và mức tăng học tập là thước đo hiệu quả của vòng IFA đó.

3.6 Liên kết bốn lý thuyết

Điều đáng chú ý là bốn lý thuyết này không rời rạc mà ghép thành một hệ thống thiết kế mạch lạc, mỗi lý thuyết trả lời một câu hỏi sư phạm khác nhau (Hình 2).



Hình 2: Bốn trụ cột lý thuyết không rời rạc mà tạo thành một hệ thống thiết kế: mỗi lý thuyết trả lời một câu hỏi sư phạm và tương ứng một thành phần kỹ thuật trong EducationQ.

Ánh xạ từ lý thuyết sang quyết định thiết kế được tóm tắt trong Bảng 2.

Bảng 2: Ánh xạ bốn lý thuyết giáo dục sang các quyết định thiết kế trong EducationQ.

Lý thuyết	Câu hỏi thiết kế	Áp dụng trong EducationQ
ZPD	Dạy ở đâu?	Pre-test/post-test đo mức hiện tại so với mức tiềm năng.
IFA	Đánh giá thế nào?	Năm vòng hội thoại mô phỏng đánh giá quá trình trong lớp.
Scaffolding	Hỗ trợ thế nào?	Thiết kế ranh giới nội dung — ẩn các lựa chọn đáp án.
Bloom	Đo bằng gì?	Bộ chiều đánh giá định tính theo mức nhận thức.

Nhận xét. Việc neo khung vào lý thuyết kinh điển là một điểm mạnh: nó khiến mỗi lựa chọn kỹ thuật đều có lý do sư phạm, thay vì tùy tiện. Tuy nhiên, bốn lý thuyết này có *chồng lấn* — IFA và scaffolding đều xoay quanh việc điều chỉnh hỗ trợ theo phản hồi, còn Bloom và ZPD cùng nói về “độ khó phù hợp”. Sự chồng lấn này có thể khiến các chiều đánh giá phải sinh không thực sự độc lập. Ngoài ra, khung thiên về truyền thống kiến tạo (constructivist); các quan điểm như direct instruction — vốn cũng có bằng chứng hiệu quả — gần như vắng mặt. Đây là điểm đáng lưu ý khi diễn giải kết quả, và sẽ được nhóm bàn kỹ hơn ở phần đánh giá.

4 Tổng quan EducationQ

Phần này phác họa EducationQ ở *mức cao* — vừa đủ để thấy cách bốn lý thuyết ở Mục 3 được hiện thực hóa. Các chi tiết kỹ thuật (cài đặt từng tác tử, prompt template, cơ chế retry), dataset, cùng metric và kết quả thực nghiệm nằm ngoài phạm vi phần này.

4.1 Mục tiêu của khung


Mục tiêu của EducationQ không phải tạo ra một chatbot dạy học, mà là *đo* năng lực dạy học của các LLM một cách có kiểm soát và có thể tái lập. Khung biến một năng lực trừu tượng — “dạy giỏi” — thành một đại lượng đo được: mức tăng kết quả học tập của người học sau khi tương tác với mô hình đóng vai giáo viên.

4.2 Cách tiếp cận mô phỏng đa tác tử

EducationQ dựng một kịch bản mô phỏng gồm ba tác tử ngang hàng: **tác tử Học sinh** (cố định, để cô lập biến cần đo), **tác tử Giáo viên** (chính là mô hình đang được đánh giá), và **tác tử Giám khảo** (phân tích chất lượng tương tác). Cần nhấn mạnh: đây *không* phải kiểu điều phối tác tử (agent orchestration) với một bộ điều phối trung tâm và luồng điều khiển động như LangGraph hay CrewAI. Luồng ở đây cố định (pre-test → năm vòng → post-test), quan hệ giữa các tác tử là ngang hàng, và mục đích là *mô phỏng* một kịch bản giáo dục, không phải hoàn thành một tác vụ. Việc cố định luồng và cố định học sinh chính là điều biến EducationQ thành một *thí nghiệm có kiểm soát*: mọi giáo viên được đánh giá trong cùng điều kiện.

4.3 Quy trình ở mức cao

Hình 3 minh họa pipeline ba pha. Học sinh làm bài kiểm tra ban đầu (*pre-test*); sau đó giáo viên và học sinh trao đổi qua năm vòng hội thoại — mỗi vòng giáo viên đặt một câu hỏi nhằm thúc đẩy hiểu biết, học sinh phản hồi; cuối cùng học sinh làm lại bài (*post-test*). Hiệu số kết quả giữa *post-test* và *pre-test* cho ra mức tăng học tập — tín hiệu định lượng trung tâm của khung.



Hình 3: Quy trình tương tác ba pha của EducationQ: *pre-test* → năm vòng hội thoại giáo viên–học sinh → *post-test*. Nguồn: Shi và cộng sự, 2025, Figure 3.

Bốn lý thuyết ở Mục 3 hiện diện rõ trong sơ đồ này: *pre-test/post-test* phản ánh ZPD, vòng hội thoại là IFA, ràng buộc giáo viên không thấy đáp án thể hiện scaffolding, còn phần phân tích của giám khảo dựa trên thang Bloom.

4.4 Vị trí trong landscape

So với các công trình cùng hướng, EducationQ chiếm một vị trí riêng. Nhiều hệ thống mô phỏng học sinh để *huấn luyện giáo viên người* (GPTeach [16], TeachTune [17]); một số benchmark đánh giá một kỹ năng dạy đơn lẻ trên *sản phẩm tĩnh*, ví dụ chất lượng câu hỏi (Dr.Academy [18]). EducationQ khác ở chỗ vừa *động* (tương tác nhiều lượt), vừa hướng *kết quả học tập* (dù trên học sinh mô phỏng), thay vì chỉ đo chất lượng phản hồi. Bảng đối chiếu chi tiết toàn cảnh thuộc phần báo cáo riêng; ở đây chỉ cần ghi nhận tính độc đáo về vị trí của EducationQ.

Nhận xét. Lựa chọn cố định học sinh là con dao hai lưỡi: nó cho phép so sánh công bằng giữa các giáo viên, nhưng cũng đồng nghĩa khung chỉ đo năng lực dạy *một kiểu người học duy nhất*. Trong thực tế, dạy giỏi phụ thuộc rất nhiều vào *ai* là người học — một sự đánh đổi giữa tính kiểm soát và tính khái quát mà ta cần ghi nhớ.

5 Phân tích Repository

Ngoài bản thân paper, nhóm tác giả công bố toàn bộ mã nguồn và tài liệu tại kho SunriserFuture/EducationQ (giấy phép MIT). Phần này phân tích cách tổ chức kho ở góc độ *tài liệu và khả năng tái lập*, tương ứng phần được giao (README, docs/, examples/).

5.1 Cấu trúc tổng quan

Kho gồm các thành phần chính: `src/` (mã nguồn khung), `docs/` (tài liệu, hình minh họa và bản PDF của paper), `examples/` (ví dụ sử dụng), `tests/`, cùng các tệp đóng gói (`setup.py`, `pyproject.toml`, `requirements.txt`). Cách bố trí chuẩn theo quy ước một gói Python, giúp người đọc định vị nhanh.

5.2 README.md

Tệp README giới thiệu khung như một hệ “đa tác tử” nhằm *chuyển hóa và đánh giá* năng lực dạy học của LLM, và — đáng chú ý — nêu thẳng bốn lý thuyết nền (ZPD, Scaffolding, IFA, Bloom) ngay phần mở đầu. Điều này cho thấy nền tảng sư phạm không phải lớp biện minh thêm vào sau, mà là tuyên ngôn thiết kế trung tâm — khớp với lập luận ở Mục 3. README cũng tóm tắt phát hiện chính (năng lực dạy không tỉ lệ tuyến tính với quy mô; 78% đồng thuận giữa chuyên gia và đánh giá tự động) và cung cấp khối trích dẫn BibTeX chính thức.

5.3 Thư mục docs/

`docs/` chứa bản PDF của paper (2025.acl-long.1576.pdf), tài liệu hướng dẫn đóng góp (`contributing.md`) và thư mục `figures/` với các hình chính thức — bao gồm hai hình được dùng trong báo cáo này (Hình 1 và 3). Việc kèm sẵn hình gốc cho phép nhóm tái sử dụng có dẫn nguồn, bảo toàn tính trung thực của minh họa thay vì vẽ lại.

5.4 examples/ và demo

Thư mục `examples/` cung cấp ví dụ sử dụng (`basic_usage.py`) đóng vai điểm khởi đầu cho người mới — một con đường tối thiểu để chạy thử khung mà không phải đọc hết mã nguồn. Đây là thực hành tốt cho khả năng tiếp cận; tuy nhiên việc *tái lập đầy đủ* một thực nghiệm quy mô lớn còn phụ thuộc cấu hình và dữ liệu (nằm ngoài phạm vi phần này).

5.5 Vì sao tác giả chọn cách công bố này?

Mở mã nguồn (MIT), công bố dataset, kèm hình gốc và ví dụ chạy — tổ hợp này phục vụ một mục tiêu rõ ràng: *khả năng tái lập*, vốn là tiêu chí ngày càng được coi trọng ở các hội nghị hàng đầu. Với một paper mà luận điểm trung tâm đi ngược trực giác (Mục 2.6), việc cho phép cộng đồng kiểm chứng độc lập càng quan trọng để tạo niềm tin.

Nhận xét. Cách công bố này là điểm cộng đáng kể về tính minh bạch. Mặt hạn chế nằm ở chi phí tái lập: pipeline gọi API với khối lượng rất lớn, nên “mở mã nguồn” không hoàn toàn đồng nghĩa với “ai cũng chạy lại được” — rào cản chi phí vẫn hiện hữu.

6 Kết luận của paper

Section 9 của paper [1] cô đọng đóng góp thành hai phát hiện cốt lõi — cũng chính là câu trả lời cho câu hỏi “vì sao paper tồn tại”.

6.1 Quy mô không đồng nghĩa với năng lực dạy

Phát hiện thứ nhất: các mô hình mã nguồn mở nhỏ hơn có thể vượt các mô hình thương mại lớn hơn về hiệu quả dạy học. Trường hợp Llama 70B vượt Llama 405B (Mục 2.6) cho thấy thêm tham số không tự động chuyển thành dạy giỏi. Đây là sự đảo ngược trực tiếp của giả định “lớn hơn thì tốt hơn” vốn chi phối phần lớn benchmark hiện tại.

6.2 Chiến lược quan trọng hơn kho kiến thức

Phát hiện thứ hai giải thích phát hiện thứ nhất: các LLM thành công trong vai người dạy nhờ *tương tác có mục tiêu* và *phương pháp dạy thích ứng* — đặt câu hỏi đúng, phản hồi trúng đích — chứ không nhờ kho kiến thức rộng hơn. Nói cách khác, năng lực dạy là một *kỹ năng sư phạm* tách biệt với năng lực trả lời.

Hai thông điệp gói gọn

Scale $\neq$ Teaching: quy mô lớn hơn không bảo đảm dạy tốt hơn.

Strategy $>$ Knowledge: chiến lược sư phạm mới là yếu tố quyết định.

6.3 Hàm ý

Nếu hai phát hiện trên đúng, cách chúng ta chọn mô hình cho ứng dụng giáo dục cần thay đổi: không thể dựa vào điểm benchmark học thuật để suy ra hiệu quả dạy học, và cần những khung đánh giá chuyên biệt dựa trên tương tác. Xa hơn, nó gợi ý một hướng tối ưu mới — tinh chỉnh mô hình *cho mục tiêu sư phạm* thay vì chỉ mở rộng quy mô.

6.4 Một phát hiện hội tụ, không phải tuyên bố đơn lẻ

Điều củng cố độ tin cậy cho EducationQ là luận điểm “quy mô $\neq$ năng lực dạy” được một số công trình độc lập xác nhận. MathTutorBench [19] kết luận rằng “năng lực chuyên môn, thể hiện qua khả năng giải bài, không lập tức chuyển thành dạy giỏi; sư phạm và chuyên môn dường như tạo thành một sự đánh đổi”. Bridge [20] cho thấy chính *quyết định sư phạm của chuyên gia*, chứ không phải sức mạnh thô của mô hình, mới làm nên khác biệt. Sự hội tụ này cho thấy EducationQ chạm tới một quy luật chung của lĩnh vực, chứ không phải một kết quả ngẫu nhiên.

Nhận xét. Hai insight rất thuyết phục trong phạm vi thí nghiệm, nhưng độ khái quát còn là câu hỏi mở: kết quả giới hạn ở hội thoại 1-1, văn bản thuần, nội dung trình độ cao, và một học sinh mô phỏng duy nhất. Liệu một mô hình “dạy giỏi” trên GPQA có giỏi với học sinh phổ thông, với học ngôn ngữ, hay trong lớp đông người hay không — paper chưa trả lời. Đây là ranh giới giữa điều paper chứng minh được và điều ta *muốn* nó chứng minh.

7 Đánh giá cộng đồng

Phần này đánh giá mức độ tiếp nhận của EducationQ trong cộng đồng học thuật — dấu chân trích dẫn (citation footprint), tình trạng bình duyệt, các công trình trích dẫn lại cùng những

phê phán của chúng, dấu chân xã hội — rồi đặt EducationQ vào bối cảnh rộng hơn của những nỗ lực công nghiệp và khảo cứu cùng thời.

7.1 Dấu chân trích dẫn

Tính đến giữa năm 2026, Semantic Scholar ghi nhận EducationQ có khoảng 24 trích dẫn, trong đó 1 trích dẫn có ảnh hưởng (influential citation). Google Scholar không xác nhận được con số chính xác (thường cao hơn Semantic Scholar). Đây là một mức trích dẫn *khêm tốn nhưng có thực* (modest-but-real) cho một paper mới khoảng một năm sau công bố — đủ để cho thấy paper được đọc và xây dựng tiếp, dù chưa đạt mức được trích dẫn rộng rãi.

7.2 Tình trạng bình duyệt

EducationQ được chấp nhận tại ACL 2025 Main Conference, hạng mục Long Papers (OpenReview ID `mxXEmspynh`). Trang forum chỉ công khai phần tóm tắt; điểm của reviewer và meta-review không công khai — đây là thông lệ chuẩn của ACL Main Conference cho các paper được nhận. Cần lưu ý rõ: paper **không** nhận giải thưởng nào (không Best Paper, không Outstanding Paper); đây là một paper Main Conference long được chấp nhận theo tiêu chuẩn thông thường. Việc nêu rõ điều này tránh thổi phồng vị thế của paper.

7.3 Các công trình trích dẫn lại và phê phán

Một số công trình 2025–2026 trích dẫn EducationQ như nền tảng của hướng benchmark giáo dục cho LLM, và nhiều công trình định vị đóng góp của mình như một sự khắc phục các hạn chế của EducationQ.

TeachBench [21] (preprint cuối 2025/đầu 2026) đặc trưng hóa EducationQ là việc “đánh giá liệu một LLM có thể dẫn dắt học sinh giải một bài toán mục tiêu cụ thể”. Từ đó nó nêu hai phê phán đáng chú ý: (i) EducationQ “chủ yếu tập trung vào hướng dẫn ở cấp độ bài toán (problem-level guidance) hơn là năng lực dạy học theo nghĩa rộng”; và (ii) việc trực tiếp dạy đúng các câu hỏi mục tiêu “đưa vào nguy cơ rò rỉ thông tin (information leakage risk)” — nghĩa là mức tăng ALG có thể phản ánh việc thông tin về đáp án thấm vào ngữ cảnh hội thoại hơn là việc học thật sự. Đây là phê phán phương pháp luận sắc bén, cộng hưởng với điểm phản biện về tính hợp lệ của ALG bàn ở Mục 8.

EduBench [22] mở rộng theo hướng phủ rộng nhiều kịch bản giáo dục đa dạng, trích dẫn EducationQ trong nhóm công trình benchmark hóa LLM cho giáo dục. Cùng các công trình khác (các benchmark mở và framework đa tác tử cho sinh đề toán), bức tranh chung cho thấy EducationQ đang đóng vai *điểm tham chiếu nền tảng* mà các nghiên cứu sau lấy làm mốc để so sánh và cải tiến.

7.4 Dấu chân xã hội

Dấu chân xã hội của EducationQ ở mức tối thiểu (minimal). Không có thảo luận thực chất, độc lập trên Reddit, X/Twitter, Hugging Face hay blog chuyên môn. Một số dấu vết tồn tại nhưng cần đọc thận trọng: The Moonlight (themoonlight.io) chỉ là literature review tự động sinh, không phải thảo luận thực; ResearchGate lưu bản PDF; Papers with Code đã ngừng/sáp

nhập vào Hugging Face năm 2025 nên không có mục leaderboard. Mã nguồn chính thức được công bố tại kho `github.com/SunriserFuture/EducationQ`, với README nói rõ nền tảng lý thuyết là ZPD của Vygotsky cùng taxonomy Bloom. Tổng thể, mức độ lan tỏa xã hội thấp phù hợp với một paper học thuật chuyên ngành chưa đạt độ phổ biến đại chúng.

7.5 Hồ sơ nhóm tác giả

Tác giả liên hệ, Yong Xu, là một nhà nghiên cứu kỳ cựu — Dean of National Academy of Excellent Engineers tại SCUT, senior member của IEEE/ACM, với hơn 161 bài báo (27 ở các venue CCF-A). Hai đồng tác giả thứ nhất, Yao Shi và Rongkeng Liang, thuộc Education Innovation Research Institute of Guangdong và dùng email chung của tổ chức SunriserFuture. Cấu trúc này gợi ý một sự hợp tác giữa một viện nghiên cứu/công nghiệp giáo dục và một phòng lab học thuật có uy tín — một bối cảnh đáng lưu ý: paper vừa có chiều sâu học thuật, vừa mang động lực ứng dụng thực tế.

7.6 Bối cảnh rộng

Điều làm cho phát hiện của EducationQ đáng tin hơn là nó được *xác nhận độc lập* bởi các nỗ lực công nghiệp quy mô lớn dùng phương pháp tốn kém hơn nhiều.

LearnLM (Google) [23], [24] tái định khung sư phạm thành “bám sát chỉ dẫn sư phạm” (pedagogical instruction following) và đánh giá trên 7 benchmark khoa học học tập kèm so sánh sở thích theo cặp do chuyên gia thực hiện. Kết quả: chuyên gia ưa thích LearnLM với mức ưa thích trung bình +31% so với GPT-4o, +11% so với Claude 3.5 Sonnet và +13% so với Gemini 1.5 Pro. Nghiên cứu tiếp theo (2025) mở rộng thành một đấu trường với 189 nhà giáo dục, 1.333 cặp đối đầu và 206 giám khảo chuyên gia, cùng một RCT tiền đăng ký với 1.763 học sinh trung học cơ sở ở Sierra Leone. Đây là xác nhận công nghiệp độc lập rằng *sư phạm $\neq$ năng lực thô*, nhưng đạt được qua đấu trường chuyên gia đắt đỏ và RCT — chính nơi mà EducationQ thay thế bằng mô phỏng rẻ tiền.

Khanmigo (Khan Academy) [25] đại diện cho góc nhìn sản phẩm: hơn 15 triệu luồng dạy kèm trong 6 tháng thử nghiệm nội bộ, với mức cải thiện 6.1% độ đúng ở câu kế tiếp khi cho tác tử truy cập lịch sử học tập của người học. Khác với EducationQ, ngành công nghiệp dựa vào các chỉ số gắn kết (engagement) và sản phẩm thay vì mức tăng học tập đo trong mô phỏng.

Tutor CoPilot RCT [26] là minh chứng thực địa randomized rõ ràng nhất rằng các nước đi sư phạm cụ thể — tăng câu hỏi gợi mở, giảm khen chung chung — mới tạo ra tiến bộ thật ở học sinh (học sinh được hỗ trợ có xác suất nắm vững chủ đề cao hơn ~ 4 điểm phần trăm), củng cố cho diễn giải nhân quả mà EducationQ chỉ có thể gợi ý qua tương quan.

Sau cùng, hai khảo cứu hệ thống cung cấp khung định vị cho toàn bộ hướng nghiên cứu này: Wang và cộng sự [27] khảo sát tổng quan và triển vọng của LLM cho giáo dục, còn Yan và cộng sự [28] rà soát các thách thức thực tiễn và đạo đức. Cả hai đặt EducationQ vào dòng nỗ lực rộng lớn hơn nhằm vừa khai thác vừa kiểm soát rủi ro khi đưa LLM vào giáo dục.

Nhận xét. Việc nhiều công trình sau lấy EducationQ làm mốc để “vượt qua” vừa là lời khẳng định tầm ảnh hưởng, vừa cho thấy paper *mở ra* nhiều hơn là *khép lại* một hướng nghiên cứu — đúng tinh thần của một đóng góp nền tảng. Tuy nhiên, số trích dẫn khiêm tốn và dấu chân xã

hội mờ nhạt cũng nhắc ta thận trọng: đây là một viên gạch quan trọng, chưa phải một bước ngoặt đã được kiểm chứng rộng rãi.

8 Nhận xét phản biện của nhóm

Sau khi xem xét động cơ, nền tảng lý thuyết và thiết kế tổng thể của EducationQ ở các phần trước, phần này trình bày đánh giá phản biện độc lập của nhóm. Mục tiêu không phải tóm tắt lại paper mà là tách bạch rõ *đâu là đóng góp thực chất, đâu là giả định cần chất vấn, và những câu hỏi nào còn để ngỏ*. Chúng tôi đánh giá paper theo tinh thần của một hội đồng phản biện ACL: nghiêm khắc với phương pháp luận nhưng công bằng với đóng góp.

8.1 Điểm mạnh

Nhóm ghi nhận năm điểm mạnh nổi bật của EducationQ.

1. **Định hình bài toán (problem framing) xuất sắc.** Paper không dừng ở khẩu hiệu “benchmark hiện tại chưa đo được teaching” mà truy ngược tới năm chức năng giảng dạy cụ thể bị bỏ lỡ, mỗi chức năng đều neo vào một công trình giáo dục kinh điển (Palincsar, 1998; Wood, Bruner & Ross, 1976; v.v.). Khoảng trống nghiên cứu (research gap) vì thế được lập luận chặt chẽ chứ không phải tự tuyên bố.
2. **Mixed-methods cân bằng.** Bốn chỉ số định lượng (ALG, PNIR, CSS, UIC) được bổ trợ bằng 17 chiều đánh giá định tính cùng các case study chuyên gia. Sự kết hợp này cho phép vừa xếp hạng vừa *giải thích vì sao* một model dạy tốt, thay vì chỉ đưa ra một con số trần trụi.
3. **Kiểm tra độ bền vững (robustness) kỹ lưỡng.** Cross-dataset $r = 0.871$ ($p < 0.001$), test-retest variance 0.00832, và ablation đối Student Agent (Qwen 72B, Mistral Nemo) cho thấy nhóm tác giả ý thức rõ các mối đe dọa tới độ tin cậy và đã chủ động đo lường chúng.

Điểm mạnh nổi bật 1 — Content Boundary Design

Thiết kế ranh giới nội dung (content boundary design) là sáng tạo kỹ thuật đáng giá nhất của EducationQ. Thay vì chỉ dặn Teacher Agent “đừng tiết lộ đáp án” ở mức prompt — điều mà một LLM có thể vô tình vi phạm — nhóm tác giả *strip* các phương án A/B/C/D ngay ở tầng dữ liệu, buộc Teacher chỉ biết câu hỏi và phán đoán đúng/sai chứ không biết đáp án. Đây là một *ràng buộc cứng* (hard constraint), không phải lời khuyên mềm. Quan trọng hơn, nó được kiểm chứng độc lập: trong 50 cặp hội thoại do 7 nhà giáo dục rà soát, không một reviewer nào phát hiện hiện tượng lộ đáp án. Thiết kế này biến scaffolding từ kỳ vọng thành điều kiện bắt buộc của thí nghiệm.

Điểm mạnh nổi bật 2 — Khả năng tái lập (reproducibility)

EducationQ đạt chuẩn tái lập vào loại tốt nhất trong nhóm benchmark giáo dục: mã nguồn mở (MIT), dataset công khai (CC-BY-4.0), tham số tắt định (temperature 0.0), và toàn bộ prompt template được liệt kê trong Appendix. Một nhóm thứ ba về nguyên tắc có thể chạy lại pipeline và thu được cùng bảng xếp hạng. Trong bối cảnh nhiều benchmark LLM chỉ công bố kết quả mà giấu prompt, đây là một điểm cộng đáng kể về mặt liêm chính khoa học (scientific integrity).

8.2 Điểm cần thảo luận

Phần này là trọng tâm phản biện của nhóm. Chúng tôi nêu tám điểm, trong đó các điểm sắc nhất (1, 2, 3) được đóng khung để nhấn mạnh.

Điểm 1 — ALG đo “học thật” hay đo “in-context retrieval”?

Đây là chất vấn nền tảng. Trong pha post-test, Student Agent được cấp *toàn bộ* lịch sử hội thoại 5 vòng trong context window. Khi điểm số tăng lên, có hai cách giải thích cạnh tranh: (a) student thực sự *học* được khái niệm (genuine learning), hoặc (b) student chỉ *trích xuất lại* thông tin đã có sẵn trong ngữ cảnh (in-context information augmentation). Hai cơ chế này không thể tách bạch bằng thiết kế hiện tại.

Hệ quả đáng lo: nếu ALG chủ yếu phản ánh (b), thì framework đang thưởng cho model nào *cung cấp gợi ý rõ ràng nhất trong ngữ cảnh*, chứ không hẳn cho model dạy giỏi nhất. Một “teacher” nói thẳng các bước giải có thể đạt ALG cao mà không hề kích hoạt năng lực tư duy của người học.

Đề xuất kiểm chứng: bổ sung một *delayed post-test* được thực hiện ở phiên riêng, *không* có dialogue trong context. Nếu mức tăng vẫn còn được giữ lại, đó là bằng chứng mạnh cho học thật; nếu sụp đổ, phần lớn ALG chỉ là retrieval. Paper hiện không xử lý mối đe dọa này.

Điểm 2 — Student cố định: thí nghiệm có kiểm soát hay over-simplification?

Việc giữ Student Agent cố định được biện minh là “controlled experiment” để cô lập năng lực Teacher — một lập luận hợp lý về nguyên tắc. Nhưng ablation chỉ *đổi model nền* (Qwen 72B, Mistral Nemo) chứ không đổi *hành vi học tập* (learning persona). Trong thực tế lớp học, hiệu quả của một chiến lược dạy phụ thuộc mạnh vào việc người học là ai.

Một framework hoàn chỉnh nên kiểm thử với các profile học sinh đa dạng: học sinh *hay hỏi lại* (inquisitive), học sinh *dễ đồng ý* (compliant), và học sinh *hay hiểu sai* (misconception-prone). Rất có thể bảng xếp hạng sẽ đảo lộn: một Teacher giỏi với student ngoan ngoãn có thể vô dụng trước student bướng bỉnh. Đây cũng là điểm chính EducationQ tự nhận trong phần Limitations, nhưng nhóm cho rằng nó nghiêm trọng hơn mức một dòng thừa nhận.

Điểm 3 — GPT-4o chấm GPT-4o-mini: thiên lệch giám khảo (evaluator bias)?

Evaluator Agent là GPT-4o, trong khi một trong các Teacher bị chấm là GPT-4o-mini (cùng nhà cung cấp). Paper phản biện bằng lập luận “nếu có thiên lệch thì hẳn đã thiên lệch thuận”, viện dẫn việc GPT-4o-mini chỉ xếp 13/14. Nhóm cho rằng lập luận này *yếu*: thiên lệch giám khảo không nhất thiết biểu hiện thành ưu ái cùng vendor — nó có thể là sự đồng điệu về *phong cách diễn đạt* (một GPT-family evaluator có thể chấm cao các phản hồi mang văn phong GPT, bất kể chất lượng sư phạm).

Bằng chứng mạnh nhất chống lại lo ngại này là 78% đồng thuận với chuyên gia người — nhưng con số đó chỉ dựa trên 50 cặp. *Đề xuất*: cross-evaluator validation, để Claude 3.5 Sonnet và Gemini 1.5 Pro độc lập chấm cùng tập hội thoại; nếu ba giám khảo cho ra xếp hạng nhất quán, lo ngại bias gần như được loại bỏ.

- 4. Temperature 0.0 — tái lập được nhưng có đại diện không?** Tham số tắt định bảo đảm reproducibility, nhưng ứng dụng giáo dục thực tế thường chạy ở $T = 0.3\text{--}0.7$ để câu trả lời tự nhiên hơn. Một Teacher có thể dạy dỗ ở $T = 0.0$ (cứng nhắc, lặp lại) nhưng tốt ở $T = 0.5$, hoặc ngược lại. Paper không báo cáo ablation theo temperature, nên ta không biết bảng xếp hạng có ổn định qua các chế độ sinh khác nhau hay không.
- 5. Giới hạn 150 tokens/lượt — có thiên vị model hỏi ngắn?** Llama 70B trung bình chỉ dùng 73.6 tokens/lượt và đứng đầu bảng. Những model có xu hướng giải thích dài hơn bị soft limit “phạt”. Vì vậy có khả năng framework đang đo “ai dạy giỏi nhất *trong 150 tokens*” chứ không phải “ai dạy giỏi nhất nói chung”. Ablation tăng lên 250 tokens cho thấy “no gain”, nhưng điều đó không loại trừ khả năng giới hạn ngắn đã định hình ngay từ đầu phong cách thắng cuộc.
- 6. Thiếu baseline direct-instruction.** Một câu hỏi đối chứng hiển nhiên còn bỏ ngỏ: nếu Teacher chỉ viết *một* bài giải thích dài, mạch lạc thay vì 5 vòng hỏi-đáp, thì ALG là bao nhiêu? Nếu direct instruction đạt ALG xấp xỉ với quy trình IFA tương tác, thì toàn bộ kiến trúc đa vòng có nguy cơ *phức tạp hóa không cần thiết* (overcomplicate). Thiếu baseline này khiến ta khó quy công mức tăng cho riêng yếu tố “tương tác” — một thiếu sót đặc biệt đáng nói vì khung vốn nghiêng hẳn về truyền thống kiến tạo (xem Mục 3.6).
- 7. Các model đã cũ.** Tập 14 model được chọn vào khoảng tháng 9–10/2024. Bảng xếp hạng không có GPT-4o bản đầy đủ thế hệ mới, Claude 3.5 Opus, Gemini 2.0, DeepSeek V3, Llama 3.3, hay các model giáo dục chuyên biệt. Với tốc độ tiến hóa của LLM, kết luận cụ thể (vd. “Llama 70B > Llama 405B”) có thể không còn đúng với thế hệ mới — dù *thông điệp tổng quát* “scale $\neq$ teaching” nhiều khả năng vẫn bền.
- 8. Chồng lấn chiều đánh giá (dimensional overlap).** Paper tự thừa nhận 17 chiều có hiện tượng overlap: “Questioning Effectiveness” (Holistic) chồng lấn về khái niệm với “Question Relevance / Cognitive Level / Question Diversity” (Teacher-Centric). Đây không chỉ là vấn đề trình bày: khi các biến dự báo tương quan cao (multicollinearity), kết quả phân tích về *tầm quan trọng của từng predictor* có thể bị bóp méo — mà chính các kết quả đó lại được dùng để rút ra insight “questioning vs feedback”.

Mối đe dọa bao trùm: tính hợp lệ của simulated student. Tám điểm trên cộng hưởng vào một giả định nền móng duy nhất: rằng một LLM (Llama 70B) có thể *mô phỏng trung thực* một người học. Toàn bộ ALG chỉ có ý nghĩa nếu giả định này đúng. Đây không phải lo ngại lý thuyết suông: hai công trình gần đây trực tiếp chất vấn nó. Martynova và cộng sự [29] cho thấy, từ góc nhìn của giáo viên thật khi dạy “học sinh LLM”, các mô phỏng này bộc lộ những lệch lạc hệ thống so với người học thật. Anonymous [30] đặt thẳng câu hỏi liệu simulated student là “substance or illusion”. Nếu Student Agent không tái hiện trung thực động lực học tập, lỗ hổng hiểu biết và cách phạm sai của con người, thì xếp hạng teaching của EducationQ đo *khả năng dạy một LLM khác*, chứ chưa chắc đo được khả năng dạy người. Nhóm xem đây là mối đe dọa hợp lệ (validity threat) lớn nhất, và là hướng phản biện đáng theo đuổi nhất.

8.3 Câu hỏi mở

Vượt ra ngoài các điểm phản biện, nhóm nêu bốn câu hỏi mở mà EducationQ gợi ra nhưng chưa trả lời:

1. **Năng lực dạy có chuyển giao (transfer) không?** Một model giỏi dạy ở GPQA/MMLU-Pro cấp graduate liệu có giỏi dạy toán K-12, hay dạy ngoại ngữ? Teaching là một kỹ năng *tổng quát* hay *đặc thù theo miền* (domain-specific)?
2. **Có thể fine-tune để dạy giỏi hơn không?** Nếu dùng chính các hội thoại của Llama 70B làm dữ liệu fine-tune cho model khác, năng lực dạy của model đó có cải thiện? Điều này sẽ chuyển teaching từ “thuộc tính phát sinh” sang “mục tiêu huấn luyện được”.
3. **Vai trò của instruction-following.** Llama 70B có điểm IFEval 86.96 rất cao. Phải chăng “năng lực dạy” ta đo được chỉ là hệ quả của việc *tuân thủ chỉ dẫn* tốt (giữ đúng soft limit, đúng format), hay là một năng lực *sự phạm thực sự độc lập*?
4. **Dạy học đa phương thức (multimodal).** Giáo viên thật dùng bảng, hình vẽ, biểu đồ. Liệu các model multimodal (GPT-4V, Gemini với ảnh) có dạy hiệu quả hơn khi được phép dùng kênh trực quan — một chiều mà EducationQ text-only hoàn toàn bỏ qua?

8.4 Bảng đánh giá tổng thể

Tổng hợp các phân tích trên, nhóm chấm điểm EducationQ theo bảy tiêu chí trong Bảng 3. Thang điểm 5 sao; tổng quan: **4/5**.

Phán quyết (verdict). EducationQ hoàn toàn xứng đáng với một bài long paper tại ACL 2025 Main Conference. Đóng góp mạnh nhất nằm ở *định hình bài toán* và *độ chặt thực nghiệm*; hai điểm này gần như không thể tranh cãi. Hạn chế chính là *phạm vi khái quát hẹp* và câu hỏi nền tảng *rốt cuộc ALG đo điều gì*. Nhóm đánh giá đây là một viên gạch nền (foundational work) tốt cho subfield benchmarking năng lực dạy học của LLM — một xuất phát điểm vững để các công trình sau (như MathTutorBench [19] hay các benchmark outcome-based) tiếp tục mở rộng và khắc phục.

Bảng 3: Đánh giá tổng thể của nhóm về EducationQ theo bảy tiêu chí.

Tiêu chí	Đánh giá	Ghi chú
Novelty	★★★★☆	Câu hỏi nghiên cứu mới và quan trọng; content boundary design sáng tạo. Multi-agent simulation cho giáo dục không hoàn toàn mới (GPTeach, TeachTune).
Methodology	★★★★☆	Thiết kế chặt chẽ, neo vào 4 lý thuyết. Điểm trừ: ALG có thể đo in-context retrieval thay vì học thật; thiếu baseline direct-instruction.
Experimental rigor	★★★★★	14 model, 1,498 câu, ~19,474 hội thoại, cross-dataset validation, test-retest, ablation, human validation.
Reproducibility	★★★★★	Mã nguồn mở, dataset công khai, tham số tắt định, prompt chi tiết trong Appendix.
Writing quality	★★★★☆	Mạch lạc, có cấu trúc, motivation thuyết phục.
Impact	★★★★☆	Có thể thay đổi cách lựa chọn model cho ứng dụng giáo dục AI.
Generalizability	★★★☆☆	Hẹp: chỉ 1-on-1, text-only, cấp graduate, tiếng Anh, MCQ, student cố định.

9 Tổng kết

Trở lại câu hỏi trung tâm — *vì sao paper EducationQ tồn tại?* — câu trả lời có thể gói trong một mạch lập luận. Toàn bộ hệ thống benchmark hiện tại đo *khả năng trả lời*, nhưng dạy học là một năng lực khác: nó đòi hỏi đặt câu hỏi, đọc phản hồi và điều chỉnh hỗ trợ theo thời gian thực. Khoảng trống giữa hai điều này — được soi sáng bởi bốn lý thuyết giáo dục kinh điển và phơi bày bởi phát hiện phản trực giác rằng mô hình lớn hơn chưa chắc dạy giỏi hơn — chính là lý do EducationQ ra đời. EducationQ lấp khoảng trống đó bằng một thí nghiệm mô phỏng có kiểm soát, đo trực tiếp mức tăng học tập của người học, và rút ra hai thông điệp: **quy mô không đồng nghĩa với năng lực dạy**, và **chiến lược sư phạm quan trọng hơn kho kiến thức**.

Tựu trung, EducationQ tồn tại vì nó đo đúng thứ mà các benchmark khác bỏ quên — không phải mô hình *biết* bao nhiêu, mà nó khiến người học *tiến bộ* tới đâu. Hiểu được “vì sao” này là tiền đề để tiếp tục trả lời “như thế nào” và “tốt đến đâu”: chi tiết về kiến trúc đa tác tử, bộ dữ liệu, các metric định lượng và phần thẩm định chuyên gia là những bước đi tự nhiên kế tiếp của bức tranh.

10 Tài liệu tham khảo

- [1] Y. Shi, R. Liang, and Y. Xu, “EducationQ: Evaluating LLMs’ Teaching Capabilities Through Multi-Agent Dialogue Framework,” in *Proceedings of the 63rd Annual Meeting of the Association for Computational Linguistics (Volume 1: Long Papers)*, arXiv:2504.14928, Association for Computational Linguistics, 2025, pp. 32 799–32 828. doi: [10.18653/v1/2025.acl-long.1576](https://doi.org/10.18653/v1/2025.acl-long.1576)
- [2] D. Hendrycks et al., “Measuring Massive Multitask Language Understanding,” in *International Conference on Learning Representations (ICLR)*, arXiv:2009.03300, 2021.
- [3] D. Rein et al., “GPQA: A Graduate-Level Google-Proof Q&A Benchmark,” in *Conference on Language Modeling (COLM)*, arXiv:2311.12022, 2024.
- [4] L. Zheng et al., “Judging LLM-as-a-Judge with MT-Bench and Chatbot Arena,” in *Advances in Neural Information Processing Systems (NeurIPS)*, arXiv:2306.05685, 2023.
- [5] Z. Liang et al., “MathChat: Benchmarking Mathematical Reasoning and Instruction Following in Multi-Turn Interactions,” *arXiv preprint arXiv:2405.19444*, 2024.
- [6] A. S. Palincsar, “Social Constructivist Perspectives on Teaching and Learning,” *Annual Review of Psychology*, vol. 49, pp. 345–375, 1998.
- [7] C. E. Hmelo-Silver and H. S. Barrows, “Goals and Strategies of a Problem-Based Learning Facilitator,” *Interdisciplinary Journal of Problem-Based Learning*, vol. 1, no. 1, pp. 21–39, 2006.
- [8] N. Mercer and K. Littleton, *Dialogue and the Development of Children’s Thinking: A Sociocultural Approach*. London: Routledge, 2007.
- [9] A. Pardo, J. Jovanovic, S. Dawson, D. Gašević, and N. Mirriahi, “Using Learning Analytics to Scale the Provision of Personalised Feedback,” *British Journal of Educational Technology*, vol. 50, no. 1, pp. 128–138, 2019.
- [10] D. Wood, J. S. Bruner, and G. Ross, “The Role of Tutoring in Problem Solving,” *Journal of Child Psychology and Psychiatry*, vol. 17, no. 2, pp. 89–100, 1976.
- [11] L. S. Vygotsky, *Mind in Society: The Development of Higher Psychological Processes*. Cambridge, MA: Harvard University Press, 1978.
- [12] B. S. Bloom, *Taxonomy of Educational Objectives: The Classification of Educational Goals*. New York: Longmans, Green, 1956.
- [13] D. R. Krathwohl, “A Revision of Bloom’s Taxonomy: An Overview,” *Theory Into Practice*, vol. 41, no. 4, pp. 212–218, 2002.
- [14] M. A. Ruiz-Primo and E. M. Furtak, “Exploring Teachers’ Informal Formative Assessment Practices and Students’ Understanding in the Context of Scientific Inquiry,” *Journal of Research in Science Teaching*, vol. 44, no. 1, pp. 57–84, 2007.
- [15] D. Wiliam, “What Is Assessment for Learning?” *Studies in Educational Evaluation*, vol. 37, no. 1, pp. 3–14, 2011.

- [16] J. M. Markel, S. G. Opferman, J. A. Landay, and C. Piech, “GPTeach: Interactive TA Training with GPT-Based Students,” in *Proceedings of the Tenth ACM Conference on Learning @ Scale (L@S)*, 2023.
- [17] H. Jin, M. Lee, J. Park, T. S. Kim, S. Lee, and J. Kim, “TeachTune: Reviewing Pedagogical Agents Against Diverse Student Profiles with Simulated Students,” in *Proceedings of the 2025 CHI Conference on Human Factors in Computing Systems*, arXiv:2410.04078, 2025.
- [18] Y. Chen, C. Wu, S. Yan, P. Liu, and Y. Xiao, “Dr.Academy: A Benchmark for Evaluating Questioning Capability in Education for Large Language Models,” in *Proceedings of the 62nd Annual Meeting of the Association for Computational Linguistics (ACL)*, arXiv:2408.10947, 2024.
- [19] J. Macina, N. Daheim, I. Hakimi, M. Kapur, I. Gurevych, and M. Sachan, “MathTutorBench: A Benchmark for Measuring Open-Ended Pedagogical Capabilities of LLM Tutors,” in *Proceedings of the 2025 Conference on Empirical Methods in Natural Language Processing (EMNLP)*, arXiv:2502.18940, 2025.
- [20] R. E. Wang, Q. Zhang, C. Robinson, S. Loeb, and D. Demszky, “Bridging the Novice-Expert Gap via Models of Decision-Making: A Case Study on Remediating Math Mistakes,” in *Proceedings of the 2024 Conference of the North American Chapter of the Association for Computational Linguistics (NAACL)*, 2024.
- [21] Anonymous, “TeachBench: Benchmarking the Teaching Ability of Large Language Models,” *arXiv preprint arXiv:2601.21375*, 2026.
- [22] Anonymous, “EduBench: A Comprehensive Benchmarking Dataset for Evaluating LLMs in Diverse Educational Scenarios,” *arXiv preprint arXiv:2505.16160*, 2025.
- [23] LearnLM Team, Google, “LearnLM: Improving Gemini for Learning,” *arXiv preprint arXiv:2412.16429*, 2024.
- [24] LearnLM Team, Google, “Towards Effective GenAI Multi-Agent Collaboration and Pedagogy with LearnLM,” *arXiv preprint arXiv:2505.24477*, 2025.
- [25] Khan Academy, “Khanmigo: An AI-Powered Tutoring Guide and Teaching Assistant,” *Khan Academy Technical Report*, 2024.
- [26] R. E. Wang, A. T. Ribeiro, C. D. Robinson, S. Loeb, and D. Demszky, “Tutor CoPilot: A Human-AI Approach for Scaling Real-Time Expertise,” *arXiv preprint arXiv:2410.03017*, 2024.
- [27] S. Wang et al., “Large Language Models for Education: A Survey and Outlook,” *arXiv preprint arXiv:2403.18105*, 2024.
- [28] L. Yan et al., “Practical and Ethical Challenges of Large Language Models in Education: A Systematic Scoping Review,” *British Journal of Educational Technology*, vol. 55, no. 1, pp. 90–112, 2024.
- [29] D. Martynova et al., “Can LLMs Effectively Simulate Human Learners? Teachers’ Insights from Tutoring LLM Students,” in *Proceedings of the 20th Workshop on Innovative Use of NLP for Building Educational Applications (BEA)*, 2025, pp. 100–117.

- [30] Anonymous, “Simulated Students in Tutoring Dialogues: Substance or Illusion?” *arXiv preprint arXiv:2601.04025*, 2026.