

Báo cáo 1: Hệ thống Metrics Đánh giá trong EducationQ

Phân tích dựa trên paper ACL 2025 và source code `src/run/main.py`

Seminar Deep Learning

2026

Mục lục

1	1. Tổng quan	3
2	2. Metrics Định lượng	3
2.1	2.1 Pipeline đo lường	3
2.2	2.2 Progress — Absolute Learning Gain (ALG)	3
2.2.1	Định nghĩa	3
2.2.2	Triển khai trong code	3
2.3	2.3 PNIR — Positive-Negative Impact Ratio	4
2.3.1	Định nghĩa	4
2.3.2	Ý nghĩa	4
2.3.3	Tính từ kết quả thực nghiệm	4
2.4	2.4 Cross-Subject Stability (CSS)	4
2.5	2.5 Unique Improvement Count (UIC)	4
3	3. Metrics Định tính	5
3.1	3.1 Cơ chế đánh giá	5
3.2	3.2 Ba loại phân tích định tính	5
3.2.1	Loại 1: Interaction Analysis (<code>over_interaction_analysis()</code>)	5
3.2.2	Loại 2: Teacher Questions Analysis (<code>teacher_questions_analysis()</code>)	6
3.2.3	Loại 3: Student Responses Analysis (<code>student_responses_analysis()</code>)	6
3.3	3.3 Verdict và de-anonymization	6
4	4. Human Alignment Validation	7
5	5. Tóm tắt hệ thống metrics	7

6 Tài liệu tham khảo**8**

1. Tổng quan


EducationQ (Shi et al., ACL 2025) đánh giá LLM ở vai trò giáo viên thông qua hệ thống metrics hai tầng: **định lượng** (đo outcome học sinh trước và sau dạy học) và **định tính** (đánh giá hành vi sư phạm của giáo viên). Hai tầng này bổ sung cho nhau — định lượng cho biết *kết quả*, định tính giải thích *tại sao*.

Nguồn gốc metrics được xác nhận trực tiếp từ `src/run/main.py` trong repository GitHub của paper.

2. Metrics Định lượng

2.1 Pipeline đo lường

Mỗi câu hỏi chạy qua 3 giai đoạn tuần tự:



Student model (Llama 3.1 70B Instruct) được cố định xuyên suốt toàn bộ thí nghiệm. Biến duy nhất thay đổi giữa các lần chạy là **teacher model**. Thiết kế này đảm bảo mọi thay đổi về accuracy đều do chất lượng dạy học gây ra, không phải do đặc điểm của student.

2.2 Progress — Absolute Learning Gain (ALG)

2.2.1 Định nghĩa

$$\text{ALG} = \text{accuracy}_{\text{post}} - \text{accuracy}_{\text{pre}}$$

- **Dương**: teacher giúp student tiến bộ
- **Âm**: teacher gây regression
- **Bằng 0**: không thay đổi

2.2.2 Triển khai trong code

Hàm `_perform_evaluation()` tại dòng 1754–1809 của `main.py`:

```
pre_test_accuracy = pre_test_correct / total # dòng 1780
post_test_accuracy = post_test_correct / total # dòng 1781
progress = post_test_accuracy - pre_test_accuracy # dòng 1782
```

Kết quả được lưu theo từng **category** (môn học) và **overall**, cho phép so sánh tính ổn định xuyên domain.

2.3 2.3 PNIR — Positive-Negative Impact Ratio

2.3.1 Định nghĩa

$$\text{PNIR} = \frac{|\{q : \text{pre}(q) = 0, \text{post}(q) = 1\}|}{|\{q : \text{pre}(q) = 1, \text{post}(q) = 0\}|}$$

trong đó $\text{pre}(q), \text{post}(q) \in \{0, 1\}$ là kết quả trả lời của student ở câu hỏi q trước và sau dạy học.

2.3.2 Ý nghĩa

PNIR bắt được **hidden regression** mà ALG che giấu. Một teacher có thể có ALG dương (tổng thể tốt) nhưng PNIR thấp (đang làm hỏng một nhóm câu hỏi nhất định). Trong thực tế giáo dục, gây harm cho một nhóm nhỏ học sinh là không chấp nhận được ngay cả khi tổng thể “tốt”.

2.3.3 Tính từ kết quả thực nghiệm

`learning_gain(ep) :`

```
pre_ok = pre["model_prediction"] == pre["correct_answer"]
post_ok = post["model_prediction"] == post["correct_answer"]
return int(post_ok) - int(pre_ok)    # +1, 0, hoặc -1
```

`PNIR = pos_count / neg_count # khi neg_count > 0`

2.4 2.4 Cross-Subject Stability (CSS)

CSS đo mức độ **nhất quán** của teacher trên tất cả các domain:

$$\text{CSS} \approx 1 - \sigma(\text{ALG}_{\text{category}})$$

trong đó σ là độ lệch chuẩn của ALG tính theo từng môn học. CSS cao đồng nghĩa teacher dạy tốt đồng đều, không chỉ giỏi một lĩnh vực cụ thể.

2.5 2.5 Unique Improvement Count (UIC)

$$\text{UIC} = |\{q : \text{pre}(q) = 0, \text{post}(q) = 1\}|$$

UIC đo **số câu hỏi riêng biệt** mà teacher đã thành công “giải cứu”. Hai teacher có cùng ALG nhưng UIC khác nhau nếu một teacher tập trung vào câu dễ và teacher kia tập trung vào câu khó hơn.

3 Metrics Định tính

3.1 Cơ chế đánh giá

EvaluatorLLM (GPT-4o) thực hiện **pairwise blind comparison**: mỗi lần đánh giá, hai teacher được ẩn danh ngẫu nhiên thành “teacher_a” và “teacher_b” trước khi đưa cho evaluator. Sau đó kết quả được de-anonymize về tên thật.

```
# main.py dòng 746-757
if random.choice([True, False]):
    prompt_teacher_a = (teacher_1_name, teacher_1_interaction)
    prompt_teacher_b = (teacher_2_name, teacher_2_interaction)
else:
    prompt_teacher_a = (teacher_2_name, teacher_2_interaction)
    prompt_teacher_b = (teacher_1_name, teacher_1_interaction)
```

Cơ chế này giảm **positional bias** — xu hướng của LLM ưu ái vị trí “A” hoặc “B” hơn dựa trên thứ tự trình bày.

3.2 Ba loại phân tích định tính

3.2.1 Loại 1: Interaction Analysis (`over_interaction_analysis()`)

Phân tích toàn bộ cuộc hội thoại teacher–student với **5 dimensions**, mỗi dimension cho điểm 1–10 kèm phân tích text:

Dimension		Câu hỏi đánh giá
Assessment Effectiveness		Teacher có chẩn đoán đúng chỗ student hiểu sai không?
Questioning Effectiveness		Câu hỏi có kích thích phản tư, làm rõ khái niệm không?
Feedback Effectiveness		Phản hồi có chất lượng và tác động đến hiểu biết của student không?
Instructional Effectiveness	Adaptation	Teacher có điều chỉnh chiến lược, nội dung, tốc độ theo student không?

Learning Achievement	Objective	Toàn bộ buổi dạy có thúc đẩy hiểu biết sâu, kỹ năng, metacognition không?
-------------------------	-----------	---

3.2.2 Loại 2: Teacher Questions Analysis (`teacher_questions_analysis()`)

Chỉ nhìn vào câu hỏi của teacher, **6 dimensions** dựa trên Bloom's Taxonomy và lý thuyết sư phạm:

Dimension	Mô tả
Question Relevance	Câu hỏi có target đúng learning goal và điểm hiểu sai của student không?
Cognitive Level	Phân bố câu hỏi qua các tầng Bloom (remember → create)
Knowledge Dimension	Bao phủ factual / conceptual / procedural / metacognitive
Question Diversity	Sử dụng nhiều loại câu hỏi (Socratic, Brainstorm, Analytic...)
Scaffolding Progression	Câu hỏi tăng dần độ phức tạp, dựa trên câu trả lời trước
Metacognitive Promotion	Thúc đẩy student phản tư về quá trình suy nghĩ của chính mình

3.2.3 Loại 3: Student Responses Analysis (`student_responses_analysis()`)

Đánh giá câu trả lời của student — gián tiếp phản ánh chất lượng dạy học, **6 dimensions**:

Dimension	Mô tả
Response Relevance	Student có trả lời đúng trọng tâm câu hỏi không?
Cognitive Level Demonstration	Độ phức tạp tư duy trong câu trả lời
Knowledge Dimension Integration	Student có kết nối nhiều loại kiến thức không?
Response Diversity	Student tiếp cận từ nhiều góc độ, nhiều cách giải thích
Elaboration Progression	Câu trả lời ngày càng sâu sắc hơn qua các turns
Metacognitive Reflection	Student phản tư về chính quá trình suy nghĩ của mình

3.3 3.3 Verdict và de-anonymization

Output của EvaluatorLLM là JSON có schema cứng (enforced bởi `response_format` của OpenAI API):

```
{
  "teacher_a": {
    "Assessment Effectiveness": {"analysis": "...", "score": 8.0},
    ...
  },
  "teacher_b": { ... },
  "verdict": {
    "analysis": "Teacher A demonstrated ...",
    "choice": "A"
  }
}
```

Sau đó `deanonymize_evaluation()` (dòng 1025–1045) map "A"/"B"/"Tie" về tên teacher thật.

4. Human Alignment Validation

Để kiểm chứng độ tin cậy của EvaluatorLLM, tác giả thực hiện human alignment study:

So sánh	Độ đồng thuận
Human expert vs. EducationQ automated	78%
Human vs. Human (inter-annotator)	~80%

78% gần đạt upper bound của inter-human agreement, xác nhận EvaluatorLLM không áp đặt bias hệ thống.

Các trường hợp bất đồng chủ yếu ở: câu trả lời student mơ hồ, subtlety chuyên ngành, và phong cách sư phạm mang tính văn hóa địa phương.

5. Tóm tắt hệ thống metrics

Metric	Công thức	Bắt được	Triển khai
ALG	$\text{acc}_{\text{post}} - \text{acc}_{\text{pre}}$	Lợi ích tổng thể	<code>_perform_evaluation()</code>

PNIR	$ \text{pos} / \text{neg} $	Hidden harm	Tính từ learning gain
CSS	$1 - \sigma(\text{ALG}_{\text{cat}})$	Cross-domain stability	Per-category ALG
UIC	$ \text{pos improvements} $	Volume giúp đỡ thực tế	Đếm pos gains
Qualitative	Score 1–10 per dim	Hành vi sư phạm	EvaluatorLLM

6 Tài liệu tham khảo

Shi, Y., Liang, R., & Xu, Y. (2025). EducationQ: Multi-Agent Framework for Evaluating LLM Teaching Capability. *Proceedings of ACL 2025*, pp. 32799–32828.

Source code: <https://github.com/iam-Dylan/education-q>