

EducationQ: Đánh Giá Năng Lực Giảng Dạy của Các Mô Hình Ngôn Ngữ Lớn Qua Khung Đối Thoại Đa Tác Tử

Bản tóm tắt và phân tích nghiên cứu

Ngày 6 tháng 6 năm 2026

1 Một câu tóm tắt

Nghiên cứu đề xuất **EducationQ**, một khung đánh giá (benchmark framework) kiểm thử năng lực giảng dạy của các mô hình ngôn ngữ lớn (LLM) dưới vai trò là một người dạy học (teacher) tương tác, thay vì chỉ đánh giá khả năng trả lời câu hỏi đơn lẻ của mô hình.

2 Vấn đề nghiên cứu

Các hệ thống đánh giá năng lực LLM phổ biến hiện nay (như MMLU, GPQA, MATH, HumanEval) chủ yếu tập trung đo lường các khía cạnh tri thức và tư duy tĩnh thông qua kiểm tra một lượt (single-turn QA), bao gồm: kiến thức nền tảng, suy luận logic, lập trình và khả năng tuân thủ chỉ thị.

Tuy nhiên, trong lĩnh vực giáo dục, một mô hình có khả năng giải bài tập tốt không đồng nghĩa với việc mô hình đó có năng lực sư phạm tốt. Hoạt động giảng dạy đòi hỏi những kỹ năng tương tác chuyên biệt, bao gồm:

- Phát hiện và chẩn đoán các lỗ hổng kiến thức hoặc sự hiểu sai của học sinh.
- Đặt các câu hỏi gợi mở phù hợp để hướng dẫn tư duy thay vì trực tiếp đưa ra lời giải.
- Đưa ra phản hồi (feedback) mang tính định hình mà không tiết lộ đáp án.
- Linh hoạt thích ứng và điều chỉnh chiến lược giảng dạy dựa trên phản hồi của học sinh.
- Áp dụng kỹ thuật giàn giáo (*scaffolding*) để phân rã tri thức, nâng đỡ học sinh từ mức độ nhận thức hiện tại lên mức độ cao hơn.
- Khuyến khích tư duy độc lập và tự suy ngẫm lại vấn đề.

Do đó, việc chỉ sử dụng độ chính xác (accuracy) từ các bài kiểm tra truyền thống để đánh giá năng lực sư phạm tương tác của LLM là chưa đầy đủ và thiếu tính chính xác.

3 Mục tiêu của nghiên cứu

Khung đánh giá **EducationQ** được xây dựng nhằm đạt được các mục tiêu sau:

1. Mô phỏng môi trường tương tác thực tế giữa giáo viên và học sinh bằng các tác tử LLM (LLM agents).
2. Đo lường hiệu quả giảng dạy trực tiếp thông qua mức độ tiến bộ trong kết quả học tập (*learning gain*) của học sinh trước và sau khi tương tác đối thoại.

3. Phân tích các khía cạnh trong chiến lược giảng dạy của mô hình (cách đặt câu hỏi, đưa ra phản hồi, phương pháp giàn giáo và khả năng thích ứng).
4. So sánh năng lực giảng dạy của nhiều mô hình ngôn ngữ lớn khác nhau trong cùng một điều kiện kiểm thử.
5. Kiểm chứng giả thuyết liệu các mô hình có quy mô lớn hơn hoặc có điểm số benchmark cao hơn có thực sự giảng dạy hiệu quả hơn hay không.

4 Điểm mới và đóng góp chính

Điểm nổi bật nhất của nghiên cứu là việc kết hợp chặt chẽ thiết kế hệ thống đa tác tử với các lý thuyết giáo dục học kinh điển, thay vì chỉ áp dụng mô hình agent một cách thuần túy. Các đóng góp cốt lõi của nghiên cứu được tóm tắt trong Bảng 1.

Bảng 1: Các đóng góp chính của nghiên cứu EducationQ

Đóng góp	Giải thích chi tiết
Multi-agent teaching benchmark	Sử dụng hệ thống gồm 3 tác tử: Người dạy (Teacher), Học sinh (Student), và Người đánh giá (Evaluator) để mô phỏng hoạt động dạy học.
Pre-test / Interaction / Post-test	Quy trình đánh giá gồm ba giai đoạn: Học sinh làm bài trước, tương tác đối thoại với giáo viên qua nhiều lượt, và thực hiện bài kiểm tra sau.
Teaching effectiveness metric	Hiệu quả giảng dạy được đo lường trực tiếp bằng mức độ tiến bộ của học sinh (<i>learning gain</i>), gắn liền với kết quả học tập thay vì chỉ đo độ chính xác của giáo viên.
Content boundary	Thiết lập ranh giới thông tin nghiêm ngặt: Giáo viên không được tiếp cận các lựa chọn đáp án (options) để tránh hiện tượng tiết lộ kết quả trực tiếp cho học sinh.
Mixed-method evaluation	Kết hợp các chỉ số định lượng hiệu năng với phân tích định tính chuyên sâu thông qua tác tử đánh giá và các chuyên gia giáo dục là con người.
Dataset cân bằng	Xây dựng bộ dữ liệu <i>MMLU-Pro Stratified</i> bao phủ 13 môn học và 10 cấp độ khó khác nhau, kết hợp cùng <i>GPQA Diamond</i> .

5 Nền tảng lý thuyết giáo dục học

Khung đánh giá **EducationQ** được thiết kế dựa trên các lý thuyết và khái niệm giáo dục học nền tảng sau:

- **Formative Assessment (Đánh giá định hình)**: Đo lường tiến trình học tập của người học trong quá trình giảng dạy để kịp thời phát hiện sai sót và điều chỉnh phương pháp sư phạm.
- **Informal Formative Assessment - IFA (Đánh giá định hình phi chính thức)**: Diễn ra tự nhiên qua các cuộc hội thoại, hỏi-đáp trực tiếp để kiểm tra luồng tư duy của học sinh.
- **Zone of Proximal Development - ZPD (Vùng phát triển gần nhất)**: Khoảng cách giữa những gì người học có thể tự thực hiện và những gì họ có thể hoàn thành dưới sự hướng dẫn của người dạy.

- **Scaffolding (Kỹ thuật giàn giáo):** Việc cung cấp các gợi ý, hỗ trợ mang tính tạm thời và giảm dần sự trợ giúp khi người học bắt đầu tự chủ được kiến thức.
- **Bloom's Taxonomy (Thang cấp độ nhận thức Bloom):** Phân loại các mức độ nhận thức của người học từ thấp đến cao (Nhớ, Hiểu, Áp dụng, Phân tích, Đánh giá, Sáng tạo).

6 Dữ liệu và Cấu hình đầu vào

6.1 Tập dữ liệu câu hỏi

Hệ thống sử dụng tổng cộng 1,498 câu hỏi từ hai nguồn chính:

- **GPQA Diamond:** Gồm 198 câu hỏi khoa học ở trình độ sau đại học (PhD), đã được kiểm định bởi các chuyên gia.
- **MMLU-Pro Stratified:** Bộ dữ liệu gồm 1,300 câu hỏi do nhóm tác giả tự xây dựng từ bộ dữ liệu MMLU-Pro gốc (12,032 câu) theo quy trình:
 1. Tính tỷ lệ chính xác trung bình (*mean accuracy*) cho từng câu hỏi dựa trên kết quả của 10 mô hình đứng đầu.
 2. Loại bỏ danh mục chung (*other*) để đảm bảo tính phân loại rõ ràng theo chuyên ngành.
 3. Phân chia câu hỏi thành 10 mức độ khó (mỗi mức tương ứng với khoảng 10% độ chính xác).
 4. Lựa chọn ngẫu nhiên 10 câu hỏi cho mỗi sự kết hợp giữa môn học và mức độ khó. Kết quả thu được: 13 ngành học $\times$ 10 cấp độ khó $\times$ 10 câu = 1,300 câu hỏi.

6.2 Định dạng dữ liệu chuẩn hóa (Standardized Schema)

Mỗi câu hỏi đầu vào được định dạng dưới dạng cấu trúc đối tượng như sau:

```
{
  "question_id": str,
  "question": str,
  "options": list[str],
  "answer": str,
  "answer_index": int,
  "cot_content": str,
  "category": str,
}
```

6.3 Cấu hình thực nghiệm

- **Tác tử Học sinh (Student Agent):** Sử dụng mô hình *Llama 3.1 70B Instruct* làm học sinh mặc định để kiểm thử.
- **Tác tử Giáo viên (Teacher Agent):** Đánh giá lần lượt 14 mô hình ngôn ngữ lớn khác nhau.
- **Tác tử Đánh giá (Evaluator Agent):** Sử dụng *GPT-4o* hoặc *GPT-4o-mini* để phân tích định tính cuộc đối thoại.
- **Thông số đối thoại:** Giới hạn tối đa 5 lượt tương tác (*rounds*) cho mỗi câu hỏi. Khuyến nghị độ dài khoảng 150 tokens cho mỗi lượt phản hồi của giáo viên và học sinh để tối ưu hóa lượng thông tin.

7 Kết quả đầu ra của hệ thống

7.1 Kết quả định lượng

Hiệu quả giảng dạy định lượng được đánh giá qua các chỉ số:

- **Pre-test Accuracy (ACC_{pre}):** Tỷ lệ trả lời đúng của học sinh trước khi nhận được sự hướng dẫn của giáo viên.
- **Post-test Accuracy (ACC_{post}):** Tỷ lệ trả lời đúng của học sinh sau khi đối thoại với giáo viên.
- **Absolute Learning Gain (ALG):** Chỉ số tiến bộ tuyệt đối, thể hiện hiệu quả của hoạt động giảng dạy:

$$ALG = ACC_{post} - ACC_{pre} \quad (1)$$

- **Positive-Negative Impact Ratio (PNIR):** Tỷ lệ tác động tích cực/tiêu cực (giá trị thấp thể hiện mức độ tác động ổn định và tích cực hơn).
- **Cross-Subject Stability (CSS):** Độ ổn định giảng dạy giữa các môn học khác nhau (giá trị thấp thể hiện tính đồng đều và ít biến động giữa các môn học).
- **Uniquely Improved Cases (UIC):** Số lượng câu hỏi mà chỉ duy nhất một mô hình giáo viên cụ thể giúp học sinh cải thiện được kết quả từ sai thành đúng.

7.2 Kết quả định tính

Tác tử đánh giá thực hiện chấm điểm cuộc đối thoại trên thang điểm từ 1 đến 10 đối với 17 khía cạnh sự phạm, chia làm 3 nhóm chính:

- **Nhóm Tương tác (Interaction-level):** Hiệu quả đánh giá định hình, hiệu quả phản hồi, khả năng thích ứng, mức độ đạt được mục tiêu học tập.
- **Nhóm Câu hỏi của Giáo viên (Teacher-question):** Sự liên quan của câu hỏi, cấp độ tư duy kích thích, tính đa dạng của câu hỏi, tiến trình giàn giáo, mức độ thúc đẩy tư duy siêu nhận thức (*metacognition*).
- **Nhóm Phản hồi của Học sinh (Student-response):** Sự liên quan của phản hồi, cấp độ nhận thức thể hiện, tiến trình giải thích chi tiết, mức độ phản ánh siêu nhận thức của học sinh.

8 Quy trình đánh giá chi tiết (Protocol)

Hệ thống **EducationQ** vận hành tuần tự theo pipeline năm bước:

1. **Bước 1: Làm bài kiểm tra trước (Pre-test):** Tác tử Học sinh nhận câu hỏi cùng các lựa chọn và đưa ra câu trả lời cùng lập luận ban đầu để thiết lập điểm cơ sở (*baseline*).
2. **Bước 2: Tương tác đối thoại:** Tác tử Giáo viên nhận câu hỏi và phân lập luận của học sinh, nhưng **không được tiếp cận các lựa chọn đáp án (options) hay đáp án đúng**. Giáo viên phải đưa ra hướng dẫn bằng các câu hỏi gợi mở và gợi ý mà không được trực tiếp tiết lộ kết quả. Học sinh phản hồi dựa trên mức độ hiểu biết dưới tác động của giáo viên. Cuộc hội thoại kéo dài tối đa 5 lượt.
3. **Bước 3: Làm bài kiểm tra sau (Post-test):** Học sinh thực hiện trả lời lại câu hỏi ban đầu dựa trên lập luận cũ và toàn bộ nội dung thảo luận trong cuộc đối thoại.

4. **Bước 4: Đánh giá định lượng:** Đo lường mức độ tiến bộ thực tế của học sinh thông qua chỉ số tuyệt đối ALG.
5. **Bước 5: Đánh giá định tính:** Tác tử Đánh giá thực hiện đọc lại toàn bộ biên bản đối thoại và chấm điểm các chỉ số sư phạm trên thang điểm 1-10.

8.1 Ranh giới nội dung (Content Boundary)

Để đảm bảo tính khách quan và đo lường chính xác năng lực sư phạm, hệ thống áp dụng cơ chế ranh giới thông tin:

- Giáo viên hoàn toàn không được tiếp cận các lựa chọn đáp án hoặc nhãn đáp án đúng của câu hỏi.
- Học sinh không biết kết quả đúng/sai của bài kiểm tra trước trong suốt quá trình đối thoại tương tác với giáo viên.

9 Các kết quả thực nghiệm chính

9.1 Hiệu năng tổng thể

Nghiên cứu tiến hành đánh giá thực nghiệm trên 14 mô hình ngôn ngữ lớn với quy mô lớn. Bảng 2 trình bày kết quả cải thiện điểm số của học sinh dưới sự hướng dẫn của một số giáo viên tiêu biểu.

Bảng 2: Hiệu năng giảng dạy của một số mô hình tiêu biểu

Mô hình Giáo viên	ACC_pre (%)	ACC_post (%)	ALG (%)
Llama 3.1 70B Instruct	47.73	58.74	11.01
Gemini 1.5 Pro 002	47.73	55.21	7.48
Llama 3.1 405B Instruct	47.73	53.87	6.14
OpenAI o1-mini	47.73	53.57	5.84
Qwen 2.5 72B Instruct	47.73	53.14	5.41
Phi-3.5-mini Instruct	47.73	48.93	1.20

Kết luận quan trọng: Mô hình *Llama 3.1 70B Instruct* đạt hiệu quả giảng dạy tốt nhất trong cấu hình thử nghiệm này, mặc dù không phải là mô hình có tham số lớn nhất. Mô hình lớn hơn là *Llama 3.1 405B Instruct* lại cho thấy chỉ số tiến bộ sư phạm thấp hơn.

9.2 Độ ổn định của khung đánh giá

- **Độ ổn định chéo giữa các tập dữ liệu:** Điểm số năng lực giảng dạy trên hai tập dữ liệu *GPQA Diamond* và *MMLU-Pro Stratified* có hệ số tương quan rất cao ($r = 0.871, p < 0.001$).
- **Độ ổn định khi kiểm thử lại (Test-retest stability):** Phương sai trung bình của chỉ số ALG khi lặp lại thực nghiệm trên tập GPQA chính với 3 mô hình đại diện đạt mức rất thấp (0.00832).

9.3 Thế mạnh theo từng lĩnh vực môn học

Nghiên cứu chỉ ra rằng năng lực sư phạm của các mô hình có tính chuyên biệt theo từng nhóm môn học:

- *Llama 3.1 70B Instruct* vượt trội ở các môn học đòi hỏi lượng kiến thức nền tảng lớn (Tâm lý học: ALG 18%; Y tế: ALG 24%; Luật: ALG 11%).
- *OpenAI o1-mini* thể hiện ưu thế rõ rệt trong các môn khoa học tự nhiên và suy luận (Vật lý: ALG 8.6%; Toán học: ALG 9%).
- *Gemini 1.5 Pro 002* đạt hiệu quả cao trong các môn ứng dụng thực tế (Kinh doanh: ALG 8%; Kinh tế học: ALG 9%).

9.4 Phân tích theo cấp độ khó và lý thuyết ZPD

Nhiều mô hình giáo viên giúp học sinh cải thiện kết quả tốt nhất ở các câu hỏi dễ. Tuy nhiên, hai mô hình *Llama 3.1 70B* và *Llama 3.1 8B* thể hiện biểu đồ tiến bộ đạt đỉnh ở các câu hỏi có độ khó trung bình. Điều này phù hợp với lý thuyết *Vùng phát triển gần nhất (ZPD)*, khi giáo viên hỗ trợ đặc lực nhất cho người học ở vùng kiến thức mà họ có thể làm được nếu có sự nâng đỡ phù hợp.

10 Chiến lược sư phạm và Đánh giá từ chuyên gia

10.1 Phân tích chiến lược sư phạm

Thông qua phân tích các cuộc hội thoại thuộc nhóm UIC (Uniquely Improved Cases), nghiên cứu chỉ ra:

- **Llama 3.1 70B Instruct** đạt hiệu quả cao nhờ chiến lược đặt câu hỏi gợi mở tốt (*questioning strategy*), giúp điều hướng tư duy của học sinh dựa trên tiến trình lập luận hiện tại.
- **Gemini 1.5 Pro 002** thành công nhờ chất lượng phản hồi định hình (*feedback quality*), chẩn đoán nhanh chóng các hiểu lầm khái niệm và đưa ra sửa đổi đúng trọng tâm.
- Các mô hình có kích thước cực lớn (như *Llama 3.1 405B Instruct*) có xu hướng lặp lại các bài tập mang tính quy trình thay vì xây dựng hệ thống câu hỏi giàn giáo khái niệm (*conceptual scaffolding*).

10.2 Đánh giá từ chuyên gia (Human Evaluation)

Kiểm định chéo với 7 nhà giáo dục chuyên nghiệp trên 50 cặp hội thoại cho thấy:

- Đánh giá của các chuyên gia trùng khớp với tác tử đánh giá tự động (Evaluator Agent) trong **78% trường hợp**.
- Nhóm hội thoại tạo ra sự tiến bộ thực tế (Learning Gain) được các chuyên gia chấm điểm hành vi sư phạm cao hơn đáng kể (7.38/10 so với 6.41/10 ở nhóm đối chứng).
- Không ghi nhận hiện tượng rò rỉ hoặc tiết lộ trực tiếp đáp án từ phía các mô hình giáo viên trong quá trình giảng dạy.

11 Hạn chế của nghiên cứu

Mặc dù thiết kế của nghiên cứu mang tính hệ thống cao, một số hạn chế cần được lưu ý:

- **Hạn chế của Tác tử Học sinh (Student Agent):** Việc sử dụng một LLM làm học sinh chưa phản ánh đầy đủ các đặc tính tâm lý, động lực học tập, nền tảng kiến thức thực tế, hay các kiểu lỗi sai đa dạng của học sinh là con người.

- **Bối cảnh giảng dạy giới hạn:** Nghiên cứu chỉ tập trung vào mô hình giảng dạy cá nhân hóa 1-1 thông qua hình thức đối thoại phi chính thức, chưa mở rộng ra quy mô lớp học hoặc các hoạt động nhóm phức tạp.
- **Cố định số lượt tương tác:** Việc quy định cố định 5 lượt đối thoại giúp đảm bảo tính công bằng trong so sánh định lượng, nhưng chưa đo lường được tốc độ tối ưu hóa số lượt dạy của giáo viên.
- **Độ phủ của đối tượng người học:** Các câu hỏi kiểm thử tập trung vào trình độ đại học và sau đại học, chưa đánh giá năng lực giảng dạy ở các cấp học phổ thông vốn đòi hỏi cách giải thích đơn giản và trực quan hơn.
- **Thiên vị của mô hình đánh giá (Evaluator Bias):** Đánh giá tự động định tính bằng mô hình có thể gặp hiện tượng đánh giá vòng lặp (LLM tự chấm điểm cho LLM) và có thể thiên vị cho phong cách viết của một số mô hình nhất định.

12 Khuyến nghị thực hiện tái lập nghiên cứu (Reproduction)

Đối với các dự án có nhu cầu tái lập hoặc phát triển dựa trên **EducationQ**, các bước chuẩn bị sau được khuyến nghị:

1. **Chuẩn bị tài nguyên dữ liệu:**
 - Tập dữ liệu GPQA Diamond: `dataset/gpqa/dataset/gpqa_diamond.csv`
 - Tập dữ liệu MMLU-Pro Stratified: `dataset/mmlu-pro/mmlu_pro_stratified.json`
2. **Cài đặt cấu hình thử nghiệm:** Xây dựng các tệp cấu hình tham số cho mô hình giáo viên và học sinh tương ứng với các tệp tin lưu trữ trong thư mục `data/input/`.
3. **Xây dựng bộ chỉ số đo lường cốt lõi:** Tập trung thiết lập các chỉ số định lượng trước: Pre accuracy, Post accuracy, chỉ số tiến bộ tuyệt đối (ALG), và tỷ lệ PNIR.
4. **Tối ưu hóa chi phí vận hành API:**
 - Thử nghiệm trước trên một tập con nhỏ (subset) đại diện cho một vài môn học cụ thể.
 - Sử dụng 2-3 mô hình giáo viên đại diện trước khi mở rộng quy mô.