

EducationQ

Phân tích chuyên gia, độ tin cậy, demo và hướng mở rộng

Báo cáo seminar — Học phần Deep Learning

Ngày 30 tháng 6 năm 2026

Mục tiêu phần trình bày

- Tóm tắt Mục 8: phân tích chuyên gia và mức đồng thuận với con người.
- Tóm tắt Mục 9: kết luận, hạn chế và đạo đức.
- Diễn giải Phụ lục F: các case study và phiếu đánh giá chuyên gia.
- Đánh giá paper đáng tin đến đâu.
- Chỉ ra cách demo và mở rộng khung EducationQ.

EducationQ đánh giá năng lực dạy như thế nào?

Ý tưởng chính

EducationQ biến năng lực dạy của Teacher LLM thành một thí nghiệm có kiểm soát: đo trước khi dạy, cho tương tác nhiều vòng, rồi đo lại sau khi dạy.

- **Teacher:** LLM đóng vai giáo viên.
- **Student:** LLM mô phỏng học sinh.
- **Evaluator:** LLM phân tích chất lượng sư phạm.
- **Chỉ số chính:** Absolute Learning Gain (ALG).

Pipeline ba giai đoạn

1. Pre-test

Student trả lời câu hỏi trước khi được dạy.

2. Interaction

Teacher dạy trong nhiều vòng, nhưng không được tiết lộ đáp án.

3. Post-test

Student trả lời lại; hệ thống đo learning gain.

- Chỉ số định lượng dựa trên kết quả làm bài, không dựa vào ý kiến giám khảo.
- Lớp định tính giúp giải thích vì sao một Teacher dạy tốt hoặc dạy kém.

Mục 8: vì sao cần chuyên gia con người?

- ALG đo learning gain một cách khách quan.
- Nhưng phân tích định tính do evaluator agent thực hiện.
- Vì vậy, bài báo dùng chuyên gia giáo dục để kiểm chứng lớp phân tích này.

Hai vai trò của chuyên gia

- Diễn giải chiến lược sư phạm mà LLM sử dụng.
- Kiểm chứng mức tin cậy của verdict từ evaluator agent.

Case study được chuyên gia chú thích

- Learning gain đến từ chiến lược dạy, không phải từ việc tiết lộ đáp án.
- Llama 3.1 70B Instruct đặt câu hỏi có cấu trúc, hỗ trợ siêu nhận thức và bắc giàn theo nhiều mức nhận thức.
- Llama 3.1 405B Instruct mạnh hơn về năng lực tổng quát, nhưng thiên về luyện tập lặp lại.
- Gemini 1.5 Pro 002 nổi bật ở chẩn đoán và phản hồi đúng mục tiêu.
- Claude 3.5 Sonnet giới thiệu nhiều khái niệm, nhưng chưa xử lý đúng hiểu lầm cốt lõi.

Con số 78% nghĩa là gì?

Thiết kế

- 8 người chấm.
- 50 cặp hội thoại.
- Mỗi cặp gồm một phiên có gain và một phiên không có gain.
- Giáo viên được ẩn danh.

Kết quả

- 39/50 cặp trùng với verdict của agent.
- Mức đồng thuận: 78%.
- Không người chấm nào phát hiện giáo viên trực tiếp tiết lộ đáp án.

Cách trích dẫn 78% cho đúng

- Đây là **percent-agreement**: tỷ lệ lựa chọn đa số của người chấm trùng với verdict của evaluator agent.
- Bài báo không báo cáo Cohen's kappa, Fleiss' kappa, hay tương quan giữa người chấm.
- Vì vậy, 78% là bằng chứng kiểm chứng hữu ích, nhưng chưa phải đo đầy đủ độ tin cậy liên người chấm.

Mục 9: kết luận chính

- Mô hình nhỏ hơn, kể cả mã nguồn mở, có thể dạy tốt hơn mô hình thương mại lớn hơn.
- LLM dạy tốt nhờ tương tác tập trung, hướng mục tiêu và thích ứng.
- Kiến thức rộng hơn không tự động đồng nghĩa với dạy tốt hơn.
- Đánh giá LLM giáo dục cần dựa trên tương tác, không chỉ benchmark năng lực tổng quát.

Các hạn chế chính

- Chỉ xét kịch bản một-thầy-một-trò.
- Số vòng hội thoại cố định nên khó đo hiệu suất cải thiện theo thời gian.
- Chưa theo dõi nhiều phiên bản trong cùng một dòng mô hình.
- Loại trừ mô hình đa phương thức và mô hình giáo dục chuyên biệt.
- Nội dung tập trung ở bậc sau đại học đến tiến sĩ.
- Student là agent mô phỏng, chưa phải người học thật.

Quan sát trong paper

Một số mô hình OpenAI trả về `NoneType` khi xử lý câu hỏi về Chiến tranh Việt Nam (Question 5048).

- Hiện tượng gắn với tổ hợp nội dung–mô hình cụ thể.
- Chính sách kiểm duyệt có thể tạo khoảng trống trong đánh giá.
- Đây là rủi ro cần tính đến khi benchmark chứa chủ đề lịch sử hoặc chính trị nhạy cảm.

- Khung dùng để đánh giá năng lực dạy, không thay thế giáo viên con người.
- Tương tác mô phỏng chỉ là công cụ nghiên cứu và hỗ trợ.
- Cách tiếp cận một-mô-hình-học-sinh có thể tạo thiên lệch.
- Dữ liệu đến từ benchmark công khai và cần được dùng đúng giấy phép.
- Cần minh bạch về giới hạn của AI trong chủ đề giáo dục nhạy cảm.

Phụ lục F cung cấp gì?

- Transcript đầy đủ của các case study.
- Kết quả pre-test và post-test.
- Phân tích của evaluator.
- Mẫu phiếu đánh giá dành cho chuyên gia con người.

Điểm quan trọng

Phụ lục F không chỉ tóm tắt kết quả; nó cho phép kiểm tra trực tiếp cách Teacher tương tác với Student qua từng vòng.

Case F.1: Gemini 1.5 Pro vs Llama 3.1 8B

Chiều đánh giá	Gemini	Llama 8B
Assessment	9	8
Questioning	9	7
Feedback	9	7
Adaptation	9	6
Objective Achievement	9	8

- Gemini tạo post-test đúng, ALG = +1.0.
- Llama 8B không tạo gain, ALG = 0.0.

F.2: Llama 3.1 70B

- Bài toán hoa hồng.
- Teacher dò hiểu biết về làm tròn và khái niệm.
- Post-test đúng, ALG = +1.0.

F.3: Gemini 1.5 Pro

- Bài về “substantial step”.
- Hỏi kiểu Socratic về *actus reus* và ý định.
- Post-test đúng, ALG = +1.0.

- Framework có ba agent kế thừa BaseLLM.
- Client tương thích OpenAI gọi `chat.completions.create()`.
- EvalManager điều phối thứ tự gọi, input và output.
- YAML trong `src/data/input/` điều khiển dataset, Teacher, Student, Evaluator và tham số chạy.

Ba cách demo

- `demo_framework_transcript.py`: phát lại transcript, không cần API.
- `demo_ui.py`: Streamlit UI phát lại episode, phù hợp trình chiếu.
- `demo_minimal.yaml + main.py -mode complete`: chạy mini với API thật.

Notebook Kaggle có thể chạy model cục bộ bằng vLLM, giảm phụ thuộc API key và rate limit.

Điểm mạnh về độ tin cậy

- ALG dựa trên exact-match, không do LLM chấm.
- Có kiểm chứng con người: 78% trên 50 cặp hội thoại.
- Không chuyên gia nào phát hiện lộ đáp án trong mẫu chấm.
- Thứ hạng giáo viên nhất quán giữa GPQA Diamond và MMLU-Pro Stratified.
- Quy mô lớn: 14 mô hình, dữ liệu và mã nguồn công khai.

Điểm cần đề đặt

- Lớp định tính chỉ dùng một evaluator model chính là GPT-4o.
- 78% là percent-agreement, không phải kappa.
- Learning gain là in-context, chưa chứng minh kiến thức lưu lâu dài.
- Chưa có verifier tự động kiểm tra Teacher có lộ đáp án hay không.
- Student mô phỏng không thay thế người học thật.

Nhận định tổng hợp

Định lượng

Kết luận mô hình nhỏ có thể dạy tốt hơn mô hình lớn khá vững, vì dựa trên chỉ số khách quan, kiểm tra liên dataset, và dữ liệu mở.

Định tính

Các diễn giải về vì sao dạy tốt là hữu ích, nhưng cần dè dặt vì phụ thuộc vào một evaluator agent và chỉ được kiểm chứng một phần bởi con người.

Hướng mở rộng

- **Dữ liệu:** thêm dataset mới, mở rộng xuống bậc học thấp hơn.
- **Mô hình:** thêm Teacher, Student, Judge qua `base_url`.
- **Giám khảo:** dùng nhiều evaluator và báo cáo kappa.
- **Học sinh:** mô phỏng nhiều hồ sơ học sinh hoặc thử với người học thật.
- **Chỉ số:** thêm verifier chống lộ đáp án và điểm dạy tổng hợp.
- **Kịch bản:** vượt khỏi một-thầy-một-trò.

- EducationQ là một framework nghiêm túc để đánh giá năng lực dạy của LLM.
- Đóng góp chính là phương pháp luận: đo learning gain qua tương tác.
- Phần định lượng đáng tin hơn phần định tính.
- Framework dễ demo và dễ mở rộng bằng config YAML hoặc `base_url`.