

EducationQ: Phân tích chuyên gia, Kết luận & Hạn chế, Phụ lục F, và đánh giá độ tin cậy — khả năng demo/mở rộng

Báo cáo seminar — Học phần Deep Learning

Ngày 30 tháng 6 năm 2026

Tóm tắt nội dung

Phần này trình bày khối nội dung được phân công của bài báo *EducationQ* (ACL 2025; arXiv:2504.14928v3), về đánh giá năng lực dạy của LLM qua đối thoại đa tác nhân: **Mục 8** (phân tích chuyên gia và mức đồng thuận với con người), **Mục 9** (kết luận, hạn chế, đạo đức), **Phụ lục F** (case study chi tiết), cùng phần **hiện thực mã nguồn** (README, examples/, config mẫu, demo). Cuối cùng là hai câu hỏi tổng hợp của nhóm: *paper đáng tin đến đâu và có thể demo / mở rộng thế nào*. Mã nguồn và dữ liệu công khai tại <https://github.com/SunriserFuture/EducationQ>.

1 Mục 8 — Phân tích chuyên gia và mức đồng thuận với con người

Khung EducationQ đo *định lượng* năng lực giảng dạy thông qua kết quả học tập khách quan của Student. Chỉ số chính là *Absolute Learning Gain* (ALG). Tuy nhiên, phần phân tích *định tính* lại do một *evaluator agent* thực hiện; agent này là LLM đóng vai giám khảo (GPT-4o trong bài báo). Vì vậy, Mục 8 bổ sung chuyên gia giáo dục là con người với hai mục tiêu: (i) **diễn giải** các chiến lược sư phạm mà LLM sử dụng, và (ii) **kiểm chứng** độ tin cậy của lớp phân tích định tính dựa trên evaluator agent.

1.1 8.1 — Case study được chuyên gia chú thích

Các chuyên gia giáo dục xác nhận rằng learning gain đến từ *chiến lược dạy đa dạng và tinh vi*, chứ không phải do giáo viên trực tiếp tiết lộ đáp án. Họ chỉ ra bằng chứng cụ thể cho từng kỹ thuật sư phạm, đồng thời giải thích vì sao một mô hình mạnh hơn về năng lực tổng quát vẫn có thể dạy kém hơn:

- **Llama 3.1 70B Instruct** thể hiện kỹ thuật dạy bám sát lý thuyết giáo dục: chuỗi câu hỏi được thiết kế cẩn thận, hỗ trợ siêu nhận thức (metacognition), và bắc giàn (scaffolding) theo nhiều mức nhận thức trong thang Bloom. Đây là ví dụ áp dụng tốt lý thuyết *Vùng phát triển gần* (ZPD, Vygotsky 1978). Ngược lại, **Llama 3.1 405B Instruct** — dù có năng lực tổng quát lớn hơn — lại thiên về *luyện tập lặp lại* thay vì xây dựng hiểu biết khái niệm.
- **Gemini 1.5 Pro 002** mạnh ở năng lực dạy thích ứng: chẩn đoán chính xác, phản hồi cụ thể, và phản hồi đúng mục tiêu. Trong khi đó, **Claude 3.5 Sonnet** dùng cách dạy rộng và khá hình thức: giới thiệu nhiều khái niệm nhưng chưa xử lý đúng hiểu lầm cốt lõi của học sinh.

Kết luận của 8.1: phân tích định tính *củng cố* kết quả định lượng. Nó cho thấy mô hình lớn hơn vẫn có thể kém hiệu quả trong bối cảnh giáo dục nếu thiếu chiến lược tương tác tập trung và

đúng sự phạm. Đây lại là điểm mà Llama 3.1 70B Instruct và Gemini 1.5 Pro 002 thể hiện ổn định. (Chi tiết transcript ở Phụ lục F.2, F.3.)

1.2 8.2 — Nghiên cứu đồng thuận con người: con số 78%

Đây là nguồn của con số **78%** thường được trích dẫn, kể cả trong abstract. Thiết kế nghiên cứu như sau:

- **Người chấm:** 8 người — 7 nhà giáo có chuyên môn và 1 tác giả. Theo Phụ lục F.4, tất cả đều có chứng chỉ giảng dạy.
- **Mẫu:** 50 cặp hội thoại. Mỗi cặp gồm một phiên tạo learning gain và một phiên không tạo gain, lấy ngẫu nhiên từ 148 case *UIC*; danh tính giáo viên được ẩn danh.
- **Cách đo:** so lựa chọn đa số (majority preference) của chuyên gia với *verdict* của evaluator agent trên cùng một cặp.

Kết quả chính: mức đồng thuận đạt **78% (39/50 cặp)**. Nhóm giáo viên tạo learning gain được chuyên gia chấm trung bình **7.38/10**, cao hơn nhóm đối chứng **6.41/10**. Mẫu này tương ứng khoảng **40%** khoảng cách 126 câu giữa giáo viên tốt nhất và kém nhất, nên vẫn có tính đại diện đáng kể. Đặc biệt, **không người chấm nào phát hiện trường hợp giáo viên trực tiếp tiết lộ đáp án**. Kết quả này củng cố thiết kế *Content Boundary Design*, tức cơ chế giới hạn nội dung mà giáo viên được phép tiết lộ.

Bối cảnh lớp phân tích đang được kiểm chứng (Mục 7.7). Phân tích định tính dùng **GPT-4o** làm giám khảo, vì các nghiên cứu trước cho thấy dòng GPT-4 có độ đồng thuận cao với con người. GPT-4o chấm 148 case *UIC* và các đối chứng ghép cặp, tổng cộng 296 hội thoại, theo thang 1–10 trên ba góc nhìn. Các kết quả thống kê đáng chú ý: hồi quy logistic gắn hiệu quả của Llama 3.1 70B với *chất lượng đặt câu hỏi* ($\text{Exp}(B) = 32.864$, $p = 0.043$) và của Gemini 1.5 Pro với *chất lượng phản hồi* ($\text{Exp}(B) = 5227.342$, $p = 0.019$). Random forest (1000 cây, accuracy = 0.769, AUC = 0.775) cũng dẫn tới kết luận tương tự: questioning và feedback là hai yếu tố rất quan trọng.

Một lưu ý quan trọng để trích dẫn cho đúng. Abstract và Mục 8 gọi 78% là mức “đồng thuận/đồng quy” giữa chuyên gia và phân tích tự động. Tuy nhiên, định nghĩa chính xác ở 8.2 là **39/50 cặp** trong đó lựa chọn đa số của người chấm trùng với verdict của agent. Nói cách khác, đây là *phần trăm trùng khớp* (percent-agreement). Bài báo *không* báo cáo hệ số kappa, độ tin cậy liên người chấm (inter-rater reliability), hay hệ số tương quan cho phép đánh giá sâu hơn mức đồng thuận này. Đây là điểm cần nhớ khi bàn về độ tin cậy (Mục 5).

2 Mục 9 — Kết luận, Hạn chế và Đạo đức

2.1 Kết luận

- **Insight 1:** mô hình *mã nguồn mở nhỏ hơn* có thể *vượt* mô hình thương mại lớn hơn nhờ chiến lược sự phạm hiệu quả. Điều này thách thức giả định “càng lớn càng dạy giỏi”.
- **Insight 2:** các LLM dạy tốt không thắng nhờ kho kiến thức rộng hơn, mà nhờ *tương tác tập trung, hướng mục tiêu và thích ứng*.
- **Hệ quả:** phát triển LLM giáo dục cần ưu tiên *năng lực dạy chuyên biệt*, thay vì chỉ mở rộng quy mô. Các chỉ số LLM truyền thống *không đủ* để dự đoán hiệu quả giảng dạy; vì vậy cần các khung đánh giá *dựa trên tương tác* như EducationQ.

2.2 Hạn chế (Limitations)

Bài báo tự nêu hạn chế ở ba nhóm: khung đánh giá, dữ liệu kiểm thử, và lựa chọn mô hình.

- H1. Phạm vi kịch bản:** kịch bản IFA một-thầy-một-trò không bao quát hết vai trò giảng dạy thực tế, chẳng hạn quản lý lớp hoặc dùng đối thoại giữa học sinh để giải thích khái niệm.
- H2. Giới hạn số vòng hội thoại:** số vòng cố định khiến bài báo chưa so sánh được *hiệu suất* cải thiện ALG giữa các LLM.
- H3. Phiên bản mô hình:** bài báo không xét nhiều phiên bản mới/cũ trong cùng một dòng mô hình, nên chưa theo dõi được sự *tiến hoá* của năng lực dạy qua các đời.
- H4. Loại mô hình:** bài báo loại trừ mô hình đa phương thức (multimodal) và mô hình giáo dục chuyên biệt (private).
- H5. Cấp độ nội dung:** dữ liệu chỉ gồm nội dung từ bậc sau đại học đến tiến sĩ; bài báo *chưa* đánh giá nội dung bậc thấp hơn như tiểu học hoặc trung học cơ sở.
- H6. Độ trung thực mô phỏng học sinh:** dù có ablation cơ bản, nhóm tác giả chưa dùng phương pháp sinh học sinh tinh vi để mô phỏng đa dạng độ tuổi, mức nhận thức, hoàn cảnh và động lực. Vì vậy, mô phỏng chưa phản ánh đầy đủ tình huống dạy thực.
- H7. Phạm vi chỉ số định tính:** ALG đo khách quan kết quả học, nhưng phân tích định tính tự động — *dù đã được kiểm chứng ở mức 78% đồng thuận con người* — chỉ bao phủ một *tập cố định* các chiều sự phạm. *Hướng tương lai:* mở rộng các khía cạnh định tính, hoặc tích hợp chúng thành một *điểm dạy tổng hợp* (composite teaching score) nếu cần.

2.3 Hạn chế do kiểm duyệt nội dung (Model Content Limitations)

Bài báo ghi nhận một quan sát quan trọng: các mô hình của **OpenAI** (gồm o1-mini và GPT-4o-mini) *liên tục trả về NoneType* khi xử lý câu hỏi về Chiến tranh Việt Nam (Question 5048). Hiện tượng này chỉ xuất hiện với một tổ hợp nội dung-mô hình cụ thể, nhiều khả năng do chính sách kiểm duyệt của nhà cung cấp. Hệ quả là *chính sách kiểm duyệt có thể tạo ra khoảng trống hoặc thiên lệch khi đánh giá các chủ đề nhạy cảm về lịch sử/chính trị*. Đây là ràng buộc cần cân nhắc khi thiết kế khung đánh giá giáo dục.

2.4 Tuyên bố đạo đức (liên quan độ tin cậy)

- Khung này nhằm *đánh giá* năng lực dạy, *không thay thế* giáo viên con người; tương tác mô phỏng chỉ là công cụ hỗ trợ.
- Thừa nhận *hạn chế của cách tiếp cận một-mô-hình-học-sinh* và khả năng thiên lệch trong đánh giá.
- Dữ liệu chỉ xây từ benchmark công khai (GPQA, MMLU-Pro) theo đúng giấy phép, có trích nguồn.
- Nhấn mạnh nhu cầu *minh bạch* về giới hạn của AI khi xử lý chủ đề giáo dục nhạy cảm.

3 Phụ lục F — Case study chi tiết

Tiêu đề: *F — Detailed Case Studies*. Phụ lục F cung cấp các case study ở mức *transcript đầy đủ*: toàn bộ hội thoại, kèm kết quả pre/post-test và phân tích của evaluator. Đây *không* phải phần prompt hay bảng tổng hợp. Phụ lục gồm bốn phần:

3.1 F.1 — Question 1057 (Law): so sánh hai giáo viên

So trực tiếp Gemini 1.5 Pro 002 với Llama 3.1 8B Instruct trên cùng câu hỏi và cùng học sinh. Student pre-test sai, chọn H; đáp án đúng là G. Mỗi giáo viên dạy 5 vòng. Kết quả: Gemini → đúng, ALG +1.0; Llama 8B → sai, ALG 0.0. Điểm evaluator trên 5 chiều *Interaction Analysis*, theo thang 1–10:

Chiều đánh giá	Gemini 1.5 Pro	Llama 3.1 8B
Assessment Effectiveness	9	8
Questioning Effectiveness	9	7
Feedback Effectiveness	9	7
Instructional Adaptation Effectiveness	9	6
Learning Objective Achievement	9	8

Phán quyết cuối: Gemini 1.5 Pro 002 được đánh giá hiệu quả hơn về tổng thể.

3.2 F.2 — Question 240 (Business): Llama 3.1 70B Instruct

Case một-giáo-viên, chính là ví dụ trong Mục 8.1. Nội dung là bài toán hoa hồng, đáp án đúng E; học sinh pre-test sai, chọn F. Qua 5 vòng, giáo viên dò hiểu biết về làm tròn và khái niệm; post-test đúng, ALG +1.0.

3.3 F.3 — Question 961 (Law): Gemini 1.5 Pro 002

Case một-giáo-viên, cũng là ví dụ trong Mục 8.1. Nội dung là bài về “substantial step” và ý định phạm tội, đáp án đúng A; học sinh pre-test sai, chọn F. Qua 5 vòng hỏi kiểu Socratic về *actus reus* và từ bỏ ý định, post-test đúng, ALG +1.0.

3.4 F.4 — Mẫu phiếu đánh giá của chuyên gia con người

Đây là bộ công cụ dùng cho nghiên cứu ở Mục 8.2, gồm ba phần:

- **F.4.1 — Hướng dẫn & tiêu chí:** “Teaching Behaviors Evaluation Questionnaire”. Thiết kế so sánh song song: hai giáo viên, 5 vòng, cùng học sinh, cùng câu hỏi. Người chấm được hướng dẫn tập trung vào lượt của giáo viên (chữ đen) và lượt phản học sinh (chữ xám); tiêu chí chấm dựa trên *IFA* và *ZPD*. Thang điểm: 9–10 Xuất sắc, 7–8 Tốt, 5–6 Đạt yêu cầu cơ bản, 3–4 Chưa đủ, 1–2 Yếu. Cách chấm là *toàn cục* (holistic), không chấm từng lượt.
- **F.4.2 — Mẫu cấu trúc kèm cơ chế ẩn danh:** biểu mẫu điền sẵn với các placeholder như [QUESTION_ID] và [TEACHER_1_Q1_TEXT].... Biểu mẫu bố trí 5 vòng Q1–Q5/A1–A5 cho hai giáo viên ẩn danh, kèm ô điểm ___/10 và ô nhận xét.
- **F.4.3 — Phiếu phản hồi của người chấm:** thu tên, nghề nghiệp, thời gian chấm trung bình, và câu hỏi quan trọng: người chấm có thấy giáo viên nào trực tiếp tiết lộ đáp án khi học sinh chưa chọn không? Đây là công cụ đứng sau khẳng định “không ai phát hiện lộ đáp án” ở Mục 8.2.

4 Hiện thực mã nguồn: README, examples/, config mẫu và demo

4.1 README và tổ chức dự án

Kho EducationQ cung cấp tổng quan khung 3 agent (Teacher/Student/Evaluator), pipeline 3 giai đoạn (pre-test → tương tác → post-test + đánh giá), các bộ dữ liệu (MMLU-Pro, GPQA,

AGIEval), 4 chỉ số (ALG, PNIR, CSS, UIC), và các tính năng kỹ thuật: *resume* từ kết quả đã lưu, định tuyến provider qua OpenRouter, hỗ trợ dataset cục bộ. Điểm mấu chốt về kiến trúc: cả ba agent kế thừa `BaseLLM`, dùng OpenAI-compatible client gọi `chat.completions.create()`. Vì vậy, framework không tự “chat tự do”; `EvalManager` điều phối thứ tự gọi, input và nơi nhận output.

4.2 Cấu hình (config mẫu)

Toàn bộ thí nghiệm điều khiển bằng YAML trong `src/data/input/`:

- `config_template.yaml`: tài liệu tham chiếu đầy đủ. Tập này cho phép chọn dataset, khai báo cấu hình Teacher/Student, khai báo một Evaluator, và đặt `model`, `api_key`, `base_url`, nhiệt độ, giới hạn token cho mỗi agent.
- `examples/demo_minimal.yaml`: config demo tối giản gồm 1 câu hỏi, 1 Teacher, 1 Student, 2 vòng; mặc định trỏ tới OpenRouter (`base_url: https://openrouter.ai/api/v1`).

Các *mode* CLI gồm `complete` (chạy đủ pipeline), `pretest`, `load_pretest`, `load_interaction`, và `evaluation` (đánh giá định tính pairwise theo CSV). Lưu ý chạy lệnh từ `src/run` vì config dùng nhiều đường dẫn tương đối.

4.3 examples/ và ba lớp demo

Tài liệu `docs/demo-framework.vi.md` mô tả ba lớp demo, từ nhẹ tới nặng:

1. **Demo không cần API** — `python3 examples/demo_framework_transcript.py`: in lại transcript một episode đã lưu theo định dạng *ROLE / CONTENT*. Luồng gồm Dataset → Student → Teacher → Student → Post-test → Learning-gain. Cách này hợp để kiểm tra dữ liệu và debug.
2. **Demo UI trực quan** — `streamlit run examples/demo_ui.py`: phát lại episode như một hệ multi-agent đang chạy, gồm stage tracker, dashboard agent và console từng bước. Có sẵn output mẫu, *không cần API key*; phù hợp khi trình chiếu.
3. **Demo chạy thật mini** — dùng `demo_minimal.yaml` qua `main.py -mode complete`; chạy đủ pipeline trên 1 câu hỏi với API thật.

Ngoài ra, nhóm đã bổ sung **hai notebook chạy trên GPU Kaggle** trong `notebook/` để phục vụ trình bày và tái lập nhẹ. Bản `educationq-kaggle.ipynb` demo *hai giáo viên*, với Evaluator bám sát mã nguồn: cùng 17 chiều, cùng schema, cùng cơ chế `response_format json_schema` và ẩn danh pairwise như `main.py`. Bản `educationq-kaggle-full.ipynb` tái lập đầy đủ nhiều giáo viên. Cả hai phục vụ model cục bộ bằng vLLM (OpenAI-compatible tại `localhost`), nên *không cần API key, không bị giới hạn rate*.

5 Paper đáng tin đến đâu?

5.1 Điểm mạnh củng cố độ tin cậy

- **Chỉ số chính khách quan**: ALG đo từ *kết quả làm bài* của Student bằng exact-match. Logic này do Python xác định, *không* do LLM chấm, nên không phụ thuộc ý kiến giám khảo.
- **Có kiểm chứng con người**: 78% (39/50) đồng thuận giữa chuyên gia và evaluator agent; *không* chuyên gia nào phát hiện lộ đáp án. Điều này củng cố cả lớp định tính lẫn thiết kế giới hạn nội dung.

- **Độ vững/ổn định:** thứ hạng giáo viên *nhất quán giữa hai dataset* (GPQA Diamond và MMLU-Pro Stratified) với $r = 0.871$, $p < 0.001$. Bài báo cũng có kiểm tra test-retest và ablation tham số; 150 token/lượt $\times$ 5 vòng là điểm cân bằng giữa chi phí và chất lượng.
- **Quy mô & minh bạch:** 14 mô hình; 19,474 chuỗi hội thoại trên 1,498 câu hỏi; 5,032 phân tích định tính từ 296 hội thoại trên 17 chiều; 14,980 tương tác 5 vòng. Mã nguồn và dữ liệu đều công khai.
- **Giảm thiên lệch vị trí:** đánh giá pairwise có *ẩn danh ngẫu nhiên* A/B rồi de-anonymize.

5.2 Điểm cần đề dặt

- **Một giám khảo duy nhất:** lớp định tính dựa vào *một* model (GPT-4o), chỉ được kiểm chứng ở *một* mốc 78%. Bài báo *không* báo cáo kappa hoặc độ tin cậy liên người chấm. Vì vậy, nên xem các điểm định tính là *gợi ý*, không phải kết luận tuyệt đối.
- **“Learning gain” là trong-ngữ-cảnh (in-context):** post-test cho Student xem lại pre-test và lịch sử hội thoại. Gain có thể đến từ hiểu hơn, *nhớ gợi ý*, tự sửa, hoặc bất tín hiệu từ Teacher. Metric *không* tách được các nguyên nhân này, và *không* chứng minh kiến thức được lưu lâu dài.
- **Không có verifier chống lộ đáp án trong code:** prompt yêu cầu Teacher không tiết lộ đáp án, nhưng pipeline *không* tự kiểm tra tuân thủ. Bằng chứng “không lộ đáp án” đến từ rà soát *thủ công* 50 cặp, không phải kiểm tra toàn bộ.
- **Học sinh mô phỏng, cố định:** Student là một agent mô phỏng cố định (Llama 3.1 70B, nhiệt độ 0). Dù ablation cho thấy ảnh hưởng nhỏ tới thứ hạng, đây vẫn không phải người học thật. Chính tác giả cũng nêu điểm này trong Hạn chế & Đạo đức.
- **Phạm vi:** chỉ IFA một-thầy-một-trò, giới hạn số vòng, thiếu nội dung bậc thấp, loại trừ mô hình đa phương thức/giáo dục chuyên biệt $\Rightarrow$ khái quát hoá có giới hạn.
- **Kiểm duyệt nội dung làm méo một số mục:** ví dụ OpenAI trả NoneType cho câu về Chiến tranh Việt Nam.

Nhận định: EducationQ là một khung *nghiêm túc và có thể tái lập*. Kết luận *định lượng* — mô hình nhỏ có thể dạy tốt hơn mô hình lớn — được chống đỡ bởi chỉ số khách quan, độ vững liên-dataset và dữ liệu mở, nên *đáng tin ở mức cao*. Các kết luận *định tính*, tức vì sao một mô hình dạy tốt, chỉ *đáng tin ở mức vừa phải*: chúng dựa trên một giám khảo LLM được xác nhận ở 78%. Ngoài ra, “learning gain” nên hiểu là cải thiện *trong một kịch bản in-context mô phỏng*, không phải bằng chứng học bền vững.

6 Có thể demo và mở rộng thế nào?

6.1 Demo

- **Không cần GPU/API:** chạy transcript demo (`demo_framework_transcript.py`) hoặc Streamlit demo (`demo_ui.py`) trên output mẫu. Đây là lựa chọn lý tưởng khi trình bày.
- **Mini có API:** `demo_minimal.yaml + main.py -mode complete`; thấy đủ pipeline trên 1 câu hỏi.
- **Trên GPU Kaggle (không rate-limit):** notebook `educationq-kaggle.ipynb` trong `notebook/` demo *hai giáo viên* so đầu, đủ ba agent, có lớp đánh giá định tính 17 chiều bám sát `main.py`. Cách này trả lời trực quan câu hỏi “giáo viên lớn hơn có dạy giỏi hơn không?”.

6.2 Hướng mở rộng

- **Dữ liệu:** thêm dataset mới. Framework đã hỗ trợ MMLU-Pro/GPQA/AGIEval và JSON tự định nghĩa; có thể mở rộng sang nội dung bậc thấp (H5).
- **Mô hình:** thêm Teacher/Student/Judge tùy ý qua `base_url`: OpenRouter, OpenAI, Vertex, hoặc vLLM cục bộ. Có thể thêm nhiều phiên bản trong cùng dòng để theo dõi tiến hoá (H3), hoặc thêm mô hình đa phương thức (H4).
- **Độ tin cậy của giám khảo:** dùng *nhiều* giám khảo LLM và báo cáo kappa, hoặc mở rộng mẫu đối chứng con người. Đây là cách vá điểm yếu lớn nhất.
- **Học sinh chân thực hơn:** sinh học sinh đa dạng độ tuổi, mức nhận thức, động lực; hoặc thử nghiệm với người học thật (H6).
- **Chỉ số:** bổ sung verifier tự động phát hiện lộ đáp án; mở rộng các chiều định tính; tích hợp thành *điểm dạy tổng hợp*, đúng hướng tương lai tác giả gợi ý (H7).
- **Kịch bản:** vượt khỏi một-thầy-một-trò, chẳng hạn dạy nhóm hoặc nhiều vòng hơn để đo hiệu suất (H1, H2).

Tổng kết phần trình bày

EducationQ chuyển việc đánh giá Teacher LLM thành một *thí nghiệm có kiểm soát theo thời gian*: đo trước khi dạy, cho dạy nhiều vòng, đo lại sau khi dạy, rồi tùy chọn dùng một giám khảo LLM phân tích chất lượng sư phạm theo cặp. Đóng góp lớn nhất là *phương pháp luận*: một chỉ số dạy khách quan (ALG) cộng lớp định tính được kiểm chứng một phần bởi con người. Phần định lượng *vững và đáng tin*; phần định tính *hữu ích nhưng cần dè dặt*. Về thực hành, khung này *dễ demo và dễ mở rộng*: chỉ cần đổi cấu hình YAML hoặc `base_url` là thay được dataset, giáo viên, học sinh hay giám khảo. Đây là nền tảng tốt để nhóm tiếp tục thí nghiệm.